

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi dan kemajuan dalam bidang *data science* telah mendorong perubahan paradigma dalam proses analisis data, prediksi, dan pengambilan keputusan di berbagai sektor industri. Dalam konteks ini, pendekatan *hybrid machine learning* muncul sebagai strategi inovatif yang menggabungkan keunggulan beberapa algoritma untuk mengatasi keterbatasan model tunggal serta meningkatkan akurasi, stabilitas, dan kemampuan generalisasi prediksi. Pendekatan ini menjadi semakin relevan seiring dengan kompleksitas dan ketidakpastian data dunia nyata yang terus meningkat. Sejumlah studi telah membuktikan efektivitas *hybrid machine learning* dalam berbagai aplikasi yaitu (Abuassi et al., 2025) menunjukkan peningkatan akurasi estimasi biaya dan durasi proyek konstruksi. L. Bai et al. (2024a) berhasil mengoptimalkan alokasi sumber daya dalam manajemen portofolio proyek. sementara Rosati et al. (2023) menerapkannya pada sistem pemeliharaan prediktif berbasis *Internet of Things* (IoT) untuk meningkatkan efisiensi operasional. Lebih jauh lagi, Luo et al. (2022) mengintegrasikan hybrid machine learning dengan metode Monte Carlo Simulation untuk menghasilkan estimasi risiko yang lebih komprehensif dan robust. Temuan-temuan ini secara kolektif menunjukkan bahwa hybrid machine learning memiliki potensi strategis yang besar dalam mendukung pengolahan data berbasis bukti dan pengambilan keputusan yang lebih adaptif serta akurat, menjadikannya sebagai salah satu pendekatan yang penting dalam lanskap analitik modern.

Dalam penelitian ini, PT Anugerah Nusa Teknologi dipilih sebagai objek studi karena relevansi tinggi perusahaan ini terhadap penerapan teknologi informasi dan analisis data canggih dalam pengelolaan proyek-proyek digital. PT Anugerah Nusa Teknologi bergerak di bidang pengembangan perangkat lunak, konsultasi teknologi informasi, serta solusi berbasis kecerdasan buatan, yang memerlukan pendekatan analitik modern dalam mendukung pengambilan keputusan strategis. Untuk memperoleh data empiris yang mendalam, dilakukan wawancara dengan tiga responden kunci yang memiliki peran berbeda dalam siklus proyek, yaitu seorang *Project Manager*, seorang *Business Analyst*, dan seorang *Software Developer*. Wawancara ini bertujuan untuk menggali persepsi, pengalaman, dan kebutuhan terkait penerapan teknik *hybrid machine learning* dalam mendukung prediksi, perencanaan, dan evaluasi proyek. Pemilihan ketiga responden ini mempertimbangkan keterlibatan aktif mereka dalam aktivitas yang berhubungan langsung dengan pengelolaan data, analisis risiko, dan optimalisasi proses, sehingga data yang diperoleh dapat merepresentasikan kebutuhan aktual di lapangan dan menjadi dasar dalam merancang model prediksi berbasis *hybrid machine learning* dalam penelitian ini.

Pada PT Anugerah Nusa Teknologi, pengelolaan proyek digital yang melibatkan berbagai pihak dan sumber daya seringkali menghadapi tantangan dalam perencanaan, estimasi biaya, serta manajemen risiko yang akurat. Masalah utama yang dihadapi perusahaan ini adalah ketidakpastian yang tinggi dalam estimasi durasi proyek dan alokasi sumber daya, yang sering kali berpengaruh terhadap kelancaran dan keberhasilan proyek. Untuk mengatasi masalah ini, dibutuhkan pendekatan yang lebih terstruktur dan berbasis data dalam pengambilan keputusan. Oleh karena itu, penelitian ini memanfaatkan dataset yang terdiri dari 2200 data proyek yang mencakup informasi terkait durasi proyek, biaya pengembangan dan tambahan, struktur tim berdasarkan peran dan tingkat keahlian, teknologi yang digunakan, serta rencana mitigasi risiko berdasarkan dampak dan kemungkinan terjadinya. Dataset ini dikumpulkan dari berbagai proyek yang telah dilaksanakan oleh PT Anugerah Nusa Teknologi. Dengan menganalisis data tersebut, diharapkan dapat ditemukan pola dan hubungan yang dapat membantu dalam meningkatkan akurasi prediksi serta meminimalkan risiko dalam proyek-proyek mendatang.

Beberapa penelitian sebelumnya yang relevan dengan topik ini antara lain dilakukan oleh Abuassi et al. (2025), yang mengembangkan model gabungan *hybrid machine learning* untuk meningkatkan akurasi dalam perkiraan biaya dan durasi proyek konstruksi. Temuan mereka menunjukkan bahwa dengan menggabungkan model regresi dan teknik *deep learning*, tingkat kesalahan estimasi dapat diminimalkan secara signifikan dibandingkan dengan metode yang lebih tradisional. Selain itu, L. Bai et al. (2024a) berhasil mengaplikasikan pendekatan serupa dalam pengelolaan portofolio proyek, dengan memadukan teknik optimasi dan *machine learning* untuk pengalokasian sumber daya yang lebih efisien. Hasilnya, mereka mampu meningkatkan produktivitas proyek dan menurunkan biaya operasional secara signifikan. Rosati et al. (2023) juga melakukan penerapan *hybrid machine learning* pada sistem pemeliharaan prediktif yang berbasis *Internet of Things* (IoT), yang membantu memperkirakan kerusakan peralatan dengan lebih tepat, meningkatkan efisiensi operasional. Hasil penelitian dari ketiga penelitian tersebut menegaskan bahwa penerapan teknik *hybrid machine learning* terbukti efektif dalam meningkatkan ketepatan prediksi, mengurangi ketidakpastian, dan memberikan dasar yang lebih kuat untuk pengambilan keputusan strategis dalam pengelolaan sumber daya dan perencanaan proyek. Temuan ini menjadi landasan penting untuk penelitian yang dilakukan dalam konteks pengelolaan proyek di PT Anugerah Nusa Teknologi.

Dalam penelitian ini, tiga algoritma utama digunakan untuk membangun model *hybrid machine learning* yang bertujuan untuk meningkatkan akurasi prediksi dalam konteks manajemen proyek di PT Anugerah Nusa Teknologi. Pertama, *Artificial Neural Networks* (ANN) digunakan karena kemampuannya untuk menangani masalah prediksi dengan struktur data yang kompleks dan non-

linear. Seperti yang dijelaskan oleh L. Bai et al. (2024a), ANN efektif dalam menggali pola tersembunyi dalam data dan digunakan untuk mengoptimalkan alokasi sumber daya dalam proyek, yang relevan dengan tantangan manajerial di PT Anugerah Nusa Teknologi. Kedua, *Gradient Boosting* dipilih karena teknik ini mampu meningkatkan model prediksi secara bertahap dengan mengkombinasikan sejumlah *weak model* untuk mengurangi bias dan varians pada hasil prediksi. Rosati et al. (2023) menggunakan *Gradient Boosting* untuk prediksi pemeliharaan sistem berbasis IoT, menunjukkan kemampuannya dalam meningkatkan efisiensi operasional, yang relevan dengan pengelolaan proyek yang melibatkan banyak variabel yang dinamis. Terakhir, *Naive Bayes* diterapkan karena kesederhanaannya dan efektivitasnya dalam menangani klasifikasi berbasis probabilitas, terutama dalam situasi dengan dataset yang besar dan fitur yang banyak. Seperti yang ditunjukkan oleh X. Dong & Qiu (2024), Naive Bayes telah digunakan untuk menggabungkan data prediktif dalam probabilitas risiko proyek, meskipun dengan asumsi independensi antar fitur. Gabungan dari ketiga algoritma ini diharapkan dapat memberikan model prediksi yang lebih komprehensif dan robust, mampu mengatasi kompleksitas dan ketidakpastian dalam proyek-proyek yang dikelola oleh PT Anugerah Nusa Teknologi.

Penelitian ini bertujuan untuk mengembangkan model prediksi berbasis *hybrid machine learning* yang menggabungkan algoritma *Artificial Neural Networks (ANN)*, *Gradient Boosting*, dan *Naive Bayes* untuk meningkatkan akurasi dan efisiensi pengelolaan proyek di PT Anugerah Nusa Teknologi. Dengan menggunakan data sebanyak 2200 data proyek, model ini diharapkan dapat memberikan estimasi yang lebih akurat mengenai alokasi sumber daya dan risiko proyek, serta memberikan wawasan yang lebih dalam mengenai faktor-faktor yang mempengaruhi keberhasilan proyek. Solusi yang dihasilkan dari penerapan model ini dapat membantu tim proyek dalam melakukan perencanaan yang lebih baik, meminimalkan risiko kegagalan, serta meningkatkan pengelolaan sumber daya. Hasil penelitian menunjukkan bahwa kombinasi ketiga algoritma ini memberikan hasil yang lebih optimal dibandingkan dengan penggunaan satu algoritma tunggal, dengan peningkatan akurasi prediksi yang signifikan pada setiap metrik yang diuji. Analisis lebih lanjut juga mengungkapkan bahwa integrasi teknik *hybrid machine learning* dengan data historis memungkinkan perbaikan pada proses pengambilan keputusan dan optimasi jalur proyek, yang relevansinya sangat tinggi untuk kebutuhan PT Anugerah Nusa Teknologi dalam menghadapi tantangan manajerial di industri teknologi informasi.

1.2 Identifikasi Masalah

Beberapa masalah yang teridentifikasi dalam penelitian ini mencakup tantangan kritis dalam pengelolaan proyek, termasuk kompleksitas data, ketidakpastian lingkungan, dan kebutuhan akan pendekatan yang lebih cerdas serta adaptif. Pengembangan solusi berbasis teknologi machine learning menawarkan

peluang besar, namun juga menghadirkan berbagai pertanyaan mendalam. Oleh karena itu, beberapa masalah utama yang menjadi fokus dalam penelitian ini antara lain adalah sebagai berikut:

1. Bagaimana mengembangkan model prediktif berbasis *hybrid machine learning* untuk meningkatkan akurasi dalam estimasi alokasi sumber daya dan risiko proyek?
2. Bagaimana mengintegrasikan algoritma *Artificial Neural Networks* (ANN), *Gradient Boosting*, dan *Naive Bayes* dalam satu model untuk meningkatkan efektivitas sistem pendukung keputusan dalam pengelolaan proyek?
3. Bagaimana memastikan sistem yang dikembangkan dapat menangani ketidakpastian dan perubahan dinamis yang terjadi selama siklus proyek dan tetap memberikan prediksi yang andal?

1.3 Tujuan Tugas Akhir

Adapun tujuan-tujuan spesifik yang ingin dicapai melalui penelitian ini dirancang secara mendetail dan terstruktur guna memberikan kontribusi dalam manajemen proyek yang difokuskan pada pemanfaatan pendekatan *hybrid machine learning* pada sistem pendukung keputusan. Secara lebih rinci, tujuan-tujuan spesifik dari penelitian ini adalah sebagai berikut:

1. Mengembangkan model prediktif berbasis *hybrid machine learning* yang dapat meningkatkan akurasi dalam prediksi durasi, biaya, dan risiko proyek dengan memanfaatkan algoritma *Artificial Neural Networks* (ANN), *Gradient Boosting*, dan *Naive Bayes*.
2. Merancang sistem pendukung keputusan berbasis *machine learning* yang mampu secara dinamis mengelola dan menyesuaikan alokasi sumber daya dan risiko proyek, serta memberikan rekomendasi yang dapat diimplementasikan dalam waktu nyata.
3. Memberikan wawasan dan rekomendasi terkait penerapan model prediktif berbasis *hybrid machine learning* dalam meningkatkan efisiensi dan keberhasilan proyek.

Dengan tujuan tersebut, diharapkan model yang dikembangkan dapat memberikan kontribusi signifikan dalam meningkatkan pengelolaan proyek melalui pendekatan yang berbasis data dan teknologi terkini.

1.4 Manfaat Tugas Akhir

Penelitian ini diharapkan dapat memberikan manfaat baik dari sisi akademis maupun praktis dalam pengelolaan proyek berbasis teknologi informasi. Beberapa manfaat yang diharapkan dari penelitian ini antara lain:

1. Mengembangkan model prediktif berbasis *hybrid machine learning* untuk meningkatkan akurasi estimasi alokasi sumber daya dan pengelolaan risiko proyek.
2. Mengintegrasikan algoritma *Artificial Neural Networks* (ANN), *Gradient Boosting*, dan *Naive Bayes* untuk meningkatkan efektivitas sistem pendukung keputusan dalam pengelolaan proyek.
3. Menyediakan solusi praktis untuk menangani ketidakpastian dan perubahan dinamis dalam proyek, serta memastikan sistem memberikan prediksi yang andal.
4. Memberikan kontribusi bagi pengembangan teknologi informasi dalam pengelolaan proyek, terutama dalam konteks pengambilan keputusan berbasis data yang lebih akurat dan adaptif.

1.5 Lingkup Tugas Akhir


Lingkup penelitian ini terbatas pada pengembangan model prediktif berbasis *hybrid machine learning* untuk pengelolaan proyek, dengan fokus pada optimasi alokasi sumber daya dan pengelolaan risiko. Penelitian ini mencakup beberapa aspek berikut:

1. Pengembangan model prediktif menggunakan *Artificial Neural Networks* (ANN), *Gradient Boosting*, dan *Naive Bayes* sebagai algoritma dasar, yang digabungkan dalam satu model *hybrid* untuk meningkatkan akurasi dan efektivitas prediksi.
2. Implementasi model dalam konteks pengelolaan proyek di PT Anugerah Nusa Teknologi (Ansatek), menggunakan 2200 data proyek yang mencakup informasi terkait durasi proyek, biaya pengembangan dan tambahan, struktur tim berdasarkan peran dan tingkat keahlian, teknologi yang digunakan, serta rencana mitigasi risiko berdasarkan dampak dan kemungkinan terjadinya. Evaluasi kinerja model untuk mengukur keakuratan prediksi dan efektivitas pengelolaan risiko dalam berbagai skenario proyek.
3. Penelitian ini tidak mencakup pengembangan sistem perangkat lunak secara keseluruhan atau implementasi dalam skala besar, namun lebih fokus pada penerapan model prediktif dalam konteks pengelolaan proyek dan analisis risiko yang menghasilkan Sistem Pendukung Keputusan (SPK).

1.6 Kerangka Berpikir

Kerangka berpikir dalam penelitian ini terdiri dari serangkaian tahapan yang dimulai dengan identifikasi masalah, metode dalam pengumpulan data penelitian, pemrosesan data (*data cleaning*, *data processing*, dan *data splitting*), melatih model

hybrid machine learning dengan *training dataset*, evaluasi penerapan model prediktif dengan *validation dataset*, dan menerapkannya pada Sistem Pendukung Keputusan (SPK). Tahapan tersebut adalah sebagai berikut:



Gambar 1-1 Skema Kerangka Berpikir

1.7 Sistematika Penulisan Tugas Akhir

Sistematika penulisan tugas akhir ini disusun untuk memberikan gambaran mengenai alur pembahasan dalam penelitian yang dilakukan. Adapun sistematika penulisan yang digunakan adalah sebagai berikut:

BAB I PENDAHULUAN

Bab ini menguraikan latar belakang penelitian, perumusan masalah, tujuan dan manfaat penelitian, batasan atau lingkup penelitian, kerangka berpikir yang menggambarkan alur logika penelitian, serta sistematika penulisan laporan secara keseluruhan. Bab ini bertujuan memberikan gambaran umum tentang dasar dan arah penelitian.

BAB II TINJAUAN PUSTAKA

Pada bab ini disajikan landasan teori yang relevan dengan topik penelitian, mencakup teori tentang machine learning, sistem pendukung keputusan, konsep hybrid machine learning, serta algoritma-algoritma yang digunakan, yaitu *Artificial Neural Networks* (ANN), *Gradient Boosting*, dan *Naive Bayes*. Selain itu, dibahas juga penelitian-penelitian terdahulu sebagai referensi dan pembandingan.

BAB III METODOLOGI PENELITIAN

Bab ini menjelaskan metode penelitian yang digunakan, mulai dari metode pengumpulan data, deskripsi dataset, tahapan pengolahan data, perancangan model prediktif, hingga metode evaluasi model. Bab ini menjadi pedoman teknis dalam melaksanakan penelitian.

BAB 2

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Untuk mendukung pengembangan model prediktif hybrid machine learning pada sistem pendukung keputusan dalam optimalisasi alokasi sumber daya dan mitigasi risiko proyek, beberapa penelitian sebelumnya telah dilakukan. Tabel berikut merangkum penelitian-penelitian terdahulu yang relevan, mencakup metode yang digunakan, fokus kajian, relevansi terhadap topik, serta hasil yang diperoleh dari masing-masing studi.

Tabel 2-1 Penelitian terdahulu

Penulis	Judul Penelitian	Metode	Masalah	Hasil Penelitian
Malek et al. (2023)	<i>Comparison of ensemble hybrid sampling with bagging and boosting machine learning approach for imbalanced data</i>	<i>Hybrid Model (Bagging + Boosting)</i>	Penanganan <i>dataset</i> yang sangat tidak seimbang menyebabkan model pembelajaran mesin gagal mengenali kelas minoritas dengan baik.	Kombinasi teknik <i>hybrid sampling</i> dengan metode <i>ensemble</i> seperti <i>bagging</i> dan <i>boosting</i> terbukti meningkatkan performa klasifikasi secara signifikan, khususnya pada kelas minoritas.
Mandava et al. (2024)	<i>A Comparative Analysis of Machine Learning and Deep Learning Approaches for Prediction of Chronic Kidney Disease Progression</i>	<i>Hybrid Model (ML + DL)</i>	Prediksi progresi penyakit ginjal kronis yang memerlukan akurasi tinggi serta generalisasi yang baik dalam kondisi data medis kompleks.	Pendekatan <i>deep learning</i> seperti LSTM dan CNN memberikan hasil yang lebih akurat dibanding metode pembelajaran mesin tradisional,

				terutama dalam menangkap pola temporal.
Sneha et al. (2024)	<i>Early Detection of Chronic Kidney Disease Using Different Machine Learning Algorithms</i>	<i>Hybrid Model (Multi-ML comparison)</i>	Deteksi dini penyakit ginjal kronis menggunakan algoritma ML yang akurat dan efisien dalam menangani data medis.	Model <i>gradient boosting</i> dan <i>random forest</i> menunjukkan performa terbaik dalam hal akurasi dan sensitivitas, menjadikannya cocok untuk sistem deteksi dini berbasis data.
Chong et al. (2021)	<i>Advances of Metaheuristic Algorithms in Training Neural Networks</i>	<i>Hybrid Model (Metaheuristic + ANN)</i>	Proses pelatihan ANN yang rentan terhadap <i>overfitting</i> dan konvergensi lambat memerlukan teknik optimasi tambahan.	Metaheuristik seperti PSO dan GA terbukti meningkatkan efektivitas pelatihan ANN dalam aplikasi industri, menghasilkan model yang lebih akurat dan stabil.
Kim et al. (2023)	<i>Variable Three-Term Conjugate Gradient Method for Training Artificial Neural Networks</i>	ANN	Masalah dalam mempercepat konvergensi dan stabilitas saat melatih jaringan saraf tiruan dalam skala besar.	Metode <i>conjugate gradient</i> baru yang diusulkan mempercepat pelatihan ANN dan menghasilkan konvergensi yang lebih cepat tanpa

				kehilangan akurasi.
Jun (2021)	<i>A Comparison of GBDT, RF, and ANN to Model Urban Land Use Changes</i>	<i>ANN, Gradient Boosting</i>	Perlu model yang efektif untuk memprediksi perubahan tata guna lahan di kawasan urban dengan data spasial yang kompleks.	<i>Gradient boosting decision tree</i> menghasilkan performa prediktif yang lebih baik dibandingkan ANN dan RF dalam memodelkan perubahan tata guna lahan.
G. Bai & Chandra (2023)	<i>Gradient Boosting Bayesian Neural Networks via Langevin MCMC</i>	<i>Gradient Boosting (Bayesian NN)</i>	Perlu integrasi ketidakpastian dalam prediksi jaringan saraf, sekaligus mempertahankan akurasi tinggi.	Gabungan <i>gradient boosting</i> dan <i>Bayesian neural networks</i> melalui <i>Langevin MCMC</i> menghasilkan model prediktif yang akurat dan tahan terhadap <i>overfitting</i> .
Bogdal et al. (2022)	<i>Recognition of Gasoline in Fire Debris Using Machine Learning</i>	<i>Gradient Boosting, Naive Bayes</i>	Klasifikasi otomatis bahan bakar dalam puing kebakaran menggunakan pendekatan ML yang akurat dan efisien.	<i>Gradient Boosting</i> menunjukkan performa klasifikasi tertinggi, sedangkan <i>Naive Bayes</i> cenderung memberikan hasil lebih rendah tetapi

				tetap kompetitif untuk beberapa jenis data.
Berrar (2025)	<i>Bayes' Theorem and Naive Bayes Classifier</i>	<i>Naive Bayes</i>	Kebutuhan pemahaman mendalam tentang dasar teoritis dan implementasi algoritma <i>Naive Bayes</i> .	Menyediakan penjelasan komprehensif mengenai teori <i>Bayes</i> dan aplikasi praktis <i>Naive Bayes</i> dalam berbagai <i>domain</i> seperti bioinformatika .
Wickramasinghe & Kalutarage (2021)	<i>Naive Bayes: Applications, Variations and Vulnerabilities</i>	<i>Naive Bayes</i>	Evaluasi menyeluruh terhadap variasi dan keterbatasan model <i>Naive Bayes</i> dalam berbagai kasus nyata.	Studi menunjukkan bahwa <i>Naive Bayes</i> sangat sensitif terhadap asumsi independensi dan distribusi data, serta memberikan solusi untuk mengatasi kerentanannya.

Penelitian-penelitian sebelumnya menunjukkan bahwa pendekatan *hybrid machine learning* terus berkembang sebagai strategi andal dalam menyelesaikan persoalan prediksi berbasis data, khususnya pada domain-domain yang menuntut akurasi tinggi dan penanganan data kompleks maupun tidak seimbang. Dalam konteks ini, Malek et al. (2023) mengusulkan pendekatan *hybrid* dengan mengombinasikan teknik *ensemble* seperti *bagging* dan *boosting* serta *metode resampling* untuk mengatasi ketidakseimbangan data. Hasilnya menunjukkan peningkatan akurasi model dalam mengklasifikasikan kelas minoritas secara signifikan, memperkuat bukti bahwa penggabungan teknik *sampling* dan *ensemble* dapat membangun sistem klasifikasi yang lebih adil dan andal.

Senada dengan itu, Mandava et al. (2024) melakukan analisis komparatif antara pendekatan *machine learning* tradisional dan *deep learning* dalam memprediksi progresi penyakit ginjal kronis. Penelitian ini menegaskan bahwa pendekatan *hybrid* yang menggabungkan fitur-fitur *temporal* melalui LSTM dan CNN memberikan hasil yang lebih akurat dan stabil dibandingkan model tradisional. Hal ini menunjukkan bahwa dalam konteks prediksi medis, integrasi model pembelajaran dalam dan tradisional dapat menangkap kompleksitas data secara lebih baik. Demikian pula, Sneha et al. (2024) menekankan efektivitas penggunaan model *ensemble* seperti *gradient boosting* dan *random forest* dalam deteksi dini penyakit ginjal kronis. Studi ini menggarisbawahi pentingnya eksplorasi beberapa algoritma dalam skema *hybrid* untuk mengoptimalkan sensitivitas dan akurasi.

Pendekatan *hybrid* juga banyak diterapkan dalam pengembangan model *artificial neural networks* (ANN). Chong et al. (2021) menyoroti peran algoritma metaheuristik, seperti *particle swarm optimization* (PSO) dan *genetic algorithm* (GA), dalam meningkatkan efektivitas proses pelatihan ANN. Penelitian ini menunjukkan bahwa metaheuristik mampu memperbaiki kinerja ANN dalam domain prediksi industri, terutama dalam menghindari jebakan lokal minimum. Sementara itu, Kim et al. (2023) mengembangkan metode *three-term conjugate gradient* untuk mempercepat dan menstabilkan pelatihan jaringan saraf tiruan. Hasilnya memperlihatkan peningkatan efisiensi dan kestabilan konvergensi, menjadikan metode ini sangat relevan untuk pengembangan ANN skala besar.

Dalam konteks penggabungan probabilistik dan pembelajaran mesin, G. Bai & Chandra (2023) mengintegrasikan *gradient boosting* dengan *Bayesian neural network* (BNN) menggunakan pendekatan *Langevin MCMC*. Tujuan utamanya adalah menghasilkan prediksi yang tidak hanya akurat, tetapi juga menyertakan estimasi ketidakpastian. Hasil penelitian menunjukkan bahwa model *hybrid* ini lebih tahan terhadap *overfitting* dan memberikan kepercayaan prediksi yang lebih tinggi, yang sangat penting dalam pengambilan keputusan berbasis risiko.

Pada bidang forensik, Bogdal et al. (2022) menunjukkan bahwa pendekatan *hybrid* dengan *gradient boosting*, *support vector machine* (SVM), dan *naïve Bayes* dapat digunakan untuk mengenali jejak bensin dalam puing kebakaran secara akurat. Penelitian ini menunjukkan bahwa *gradient boosting* memiliki performa tertinggi, namun integrasi model-model lain tetap relevan dalam meningkatkan robustitas sistem klasifikasi pada konteks data nyata.

Selain pendekatan *hybrid*, penelitian mengenai model tunggal juga memberikan kontribusi penting sebagai pembanding. Berrar (2025) secara teoritis menjelaskan kekuatan dan keterbatasan dari *Naive Bayes*, sedangkan Wickramasinghe & Kalutarage (2021) memberikan tinjauan mendalam mengenai

variasi dan kerentanan *Naive Bayes* dalam aplikasi dunia nyata. Kedua studi ini memperkuat pentingnya memahami asumsi dasar dan konteks penerapan model, terutama ketika model tersebut dijadikan bagian dari arsitektur *hybrid*.

Secara keseluruhan, penelitian-penelitian ini menunjukkan bahwa pendekatan *hybrid machine learning* dapat meningkatkan akurasi prediksi, mengelola ketidakpastian, serta mengatasi keterbatasan model tunggal dalam menghadapi data kompleks dan tidak seimbang. Penggunaan strategi *hybrid* tidak hanya menawarkan peningkatan kinerja teknis, tetapi juga memperluas potensi aplikasi dalam berbagai *domain* seperti medis, industri, forensik, dan analisis proyek. Temuan-temuan ini menjadi dasar yang kuat bagi pengembangan model pada penelitian ini, yang bertujuan untuk membangun sistem prediktif yang tidak hanya akurat, tetapi juga mampu memberikan wawasan strategis dan adaptif dalam konteks pengambilan keputusan berbasis data yang dinamis dan *real-time*.


Dengan demikian, seluruh penelitian terdahulu yang dikaji ini memberikan fondasi ilmiah yang kokoh untuk mendukung penelitian berjudul "Pengembangan Model Prediktif *Hybrid Machine Learning* pada Sistem Pendukung Keputusan untuk Optimalisasi *Resource Allocation* dan *Project Risks*". Penelitian ini berupaya mengintegrasikan kekuatan berbagai teknik *machine learning* dalam kerangka *hybrid* untuk mengembangkan model prediktif yang efektif dalam mengelola sumber daya dan risiko proyek secara optimal, sehingga mampu memberikan nilai tambah strategis dalam pengambilan keputusan manajerial dan operasional.

2.2 Sistem Pendukung Keputusan

Di era kontemporer dengan kelimpahan informasi dan kerumitan organisasi, kebutuhan akan instrumen pengambilan keputusan yang tepat guna menjadi sangat penting. Sistem Pendukung Keputusan (SPK) telah muncul sebagai respons teknologi yang penting untuk memenuhi kebutuhan ini. SPK didefinisikan sebagai sistem interaktif berbasis komputer yang membantu pengguna dalam memanfaatkan data dan model untuk mengatasi masalah semi-terstruktur dan tidak terstruktur (Ali et al., 2023; Hutahaean et al., 2023). Berbeda dengan sistem informasi konvensional yang hanya menyediakan data, SPK dirancang untuk secara aktif mendukung proses pengambilan keputusan, sehingga memungkinkan eksplorasi, simulasi, prediksi, dan evaluasi alternatif.

Cakupan SPK lebih dari sekadar penyajian data. SPK mengintegrasikan penilaian manusia dengan data kuantitatif dan model komputasi untuk menghasilkan wawasan yang dapat ditindaklanjuti, dan berfungsi sebagai alat bantu kognitif dalam konteks di mana intuisi saja tidak mencukupi (Gunawan et al., 2023). Sistem ini memiliki kapasitas untuk mengelola variabel yang kompleks, data yang berubah dengan cepat, dan kriteria keputusan yang beragam. Oleh karena itu, sistem ini dianggap tidak dapat dipisahkan dari lingkungan yang dinamis, termasuk

manajemen proyek, keuangan, pengelolaan sumber daya manusia, administrasi publik, hingga kebijakan sosial (Yusril et al., 2024; Zulfahmi et al., 2023).




Gambar 2-1 Diagram Alir Sistem Pendukung Keputusan

Ali et al. (2023) menyampaikan bahwa SPK sangat efektif dalam menghubungkan kesenjangan antara data mentah dan tindakan manajerial, yang berfungsi sebagai *middle layer* antara basis data dan pengambil keputusan. Pemanfaatan SPK oleh individu atau kelompok memberikan lingkungan terstruktur yang kondusif untuk pengorganisasian informasi secara sistematis, perumusan hipotesis, evaluasi asumsi, dan analisis konsekuensi potensial sebelum penentuan tindakan akhir.

Gagasan SPK pada awalnya diusulkan pada akhir tahun 1960-an oleh para ahli terkemuka seperti Gorry dan Scott Morton, yang mengembangkan taksonomi masalah keputusan berdasarkan tingkat strukturasinya. Sistem awal sebagian besar bersifat *model-driven*, dengan fokus pada pemodelan matematis untuk perencanaan strategis dan penjadwalan sumber daya. Seiring waktu, SPK berkembang menjadi lebih berbasis data dan mendukung kolaborasi antar pengguna (Gunawan et al., 2023). Munculnya metode *machine learning* dan *Explainable AI* (Antoniadi et al., 2021) menjadikan SPK lebih cerdas, adaptif, dan mampu memberikan penjelasan atas rekomendasinya.

2.2.1 Arsitektur dan Komponen

Dalam arsitekturnya, Hutahaean et al. (2023) menjelaskan bahwa SPK memiliki struktur modular dan berlapis yang dirancang untuk memastikan fleksibilitas dan skalabilitas. Umumnya, SPK terdiri atas empat komponen utama:



Gambar 2-2 Komponen Utama Sistem Pendukung Keputusan

- *Data Management*
Bertanggung jawab atas penyimpanan, penarikan, dan pengelolaan data terstruktur maupun tidak terstruktur. Komponen ini sering kali terintegrasi dengan *data warehouse*, *database real-time*, dan kini diperluas ke *big data* platform seperti *data lake* (Zulfahmi et al., 2023).
- *Model Management*
Menyediakan pustaka model analitis, matematis, statistik, hingga *machine learning*. Komponen ini memungkinkan sistem menjalankan proses klasifikasi, prediksi, optimasi, dan simulasi (Gunawan et al., 2023; Satria, 2023).
- *Knowledge Management*
Mengelola basis pengetahuan, heuristik, dan logika penalaran. Sangat relevan dalam domain semi-terstruktur seperti perencanaan sumber daya, kebijakan, dan evaluasi sosial (Yusril et al., 2024).
- *User Interface*
Antarmuka pengguna yang memungkinkan interaksi manusia-sistem secara intuitif. UI mendukung input data, pemilihan kriteria, dan visualisasi hasil seperti grafik, *heatmap*, dan *dashboard* interaktif (Siciliani et al., 2023).

Arsitektur SPK modern juga dapat mencakup teknologi lanjutan seperti *Natural Language Processing* (NLP) untuk interaksi berbasis bahasa alami, serta *Explainable AI* untuk menjelaskan hasil prediksi secara transparan dan dapat dimengerti pengguna (Antoniadi et al., 2021).

2.2.2 Karakteristik Utama

SPK memiliki sejumlah karakteristik yang membedakannya dari sistem informasi lainnya. Sprague dalam Yusril et al. (2024) membagi karakteristik SPK berdasarkan pendekatan dan penggunaannya. Berikut adalah klasifikasi karakteristik utama SPK:

Tabel 2-2 Karakteristik Utama Sistem Pendukung Keputusan


Kategori	Penggunaan
<i>Data-Driven DSS</i>	Menggunakan kumpulan data yang besar dan fokus pada <i>query</i> , penyortiran, dan pelaporan statistik
<i>Model-Driven DSS</i>	Menggunakan model matematika, keuangan, atau simulasi untuk mendukung logika keputusan.
<i>Communication-Driven DSS</i>	Memfasilitasi komunikasi dan kolaborasi kelompok
<i>Document-Driven DSS</i>	Membantu mengambil, mengklasifikasikan, dan menganalisis dokumen.
<i>Knowledge-Driven DSS</i>	Menanamkan pengetahuan ahli dan mekanisme inferensi untuk memberikan saran atau diagnosa yang sesuai

Penerapan nyata dari SPK sering kali bersifat hibrida, menggabungkan dua atau lebih pendekatan tergantung kompleksitas masalah. Misalnya, dalam sistem prediksi alokasi sumber daya proyek, digunakan kombinasi *model-driven* dan *knowledge-driven* untuk menghasilkan keputusan yang lebih akurat dan kontekstual (Ali et al., 2023; Gunawan et al., 2023).

2.3 Machine Learning

Machine Learning (ML) telah menjadi komponen penting dalam pengambilan keputusan berbasis data di era digital, termasuk dalam ranah manajemen proyek. Penerapan ML tidak hanya terbatas pada analisis data historis, tetapi telah berkembang menjadi sistem prediktif yang mampu mengidentifikasi risiko proyek, memprediksi durasi, dan mengoptimalkan alokasi sumber daya dengan presisi tinggi. Dalam lingkup pengelolaan proyek yang dinamis dan kompleks, keberadaan ML memberikan pendekatan yang lebih fleksibel, berbasis pembelajaran otomatis, dan mampu beradaptasi terhadap ketidakpastian yang tinggi. Menurut Mahdi et al. (2021), *machine learning* mampu mengolah data proyek dalam jumlah besar dan mengungkap pola tersembunyi yang sulit dikenali secara manual. Hal ini sangat berguna dalam estimasi biaya, penjadwalan ulang otomatis, hingga deteksi dini terhadap penyimpangan dari *baseline* proyek. Dalam studi mereka, algoritma seperti *decision tree*, *random forest*, dan SVM digunakan untuk klasifikasi status proyek berdasarkan parameter operasional dan anggaran.

Meningkatnya implementasi transformasi digital di berbagai industri telah berkontribusi pada pesatnya pemanfaatan teknologi *machine learning*. Dari sistem penerjemahan dan rekomendasi bahasa secara *real-time* di *e-commerce* hingga *fraud detection* di layanan keuangan, fleksibilitas *machine learning* terbukti nyata. Di dalam manajemen proyek, di mana sejumlah besar data yang dihasilkan mulai dari dokumen perencanaan, metrik pemanfaatan *resource*, komunikasi dengan pemangku kepentingan, dan penilaian risiko. *Machine learning* berfungsi sebagai perangkat pendukung analitik yang kuat. Menurut Almarhabi & Yaghi (2025), teknologi *machine learning* digunakan untuk melakukan otomatisasi dokumentasi proyek, mengidentifikasi adanya gap dalam pengetahuan, menelusuri berbagai kebutuhan *stakeholder* yang terus berkembang, dan menggali berbagai wawasan tersembunyi dari kumpulan data-data proyek yang cukup banyak dan relatif kompleks.



Gambar 2-3 Diagram Alir Machine Learning


Selain untuk otomatisasi, kemampuan prediktif *machine learning* memungkinkan manajer proyek untuk mengantisipasi potensi terjadinya keterlambatan proyek, pembengkakan biaya, atau pergeseran ruang lingkup berdasarkan kecenderungan dalam tren historis. Kemampuan prediktif ini diterjemahkan ke dalam strategi perencanaan ke depan, yang membekali pihak *decision maker* dengan informasi yang mereka butuhkan untuk mengambil tindakan proaktif. *Machine learning* juga tertanam dalam sistem pendukung keputusan (SPK), menjadikannya lebih responsif dan cerdas dengan memungkinkan kemampuan belajar mandiri.

Selain itu, seiring dengan meningkatnya adopsi organisasi terhadap metodologi proyek yang bergerak cepat, efisien, atau *hybrid*, kebutuhan akan adaptasi dan pembelajaran yang berkelanjutan menjadi semakin penting. Dalam konteks ini, *machine learning* memberikan fleksibilitas untuk menganalisis aliran data yang terus berkembang dan mendukung pengambilan keputusan secara *real-time*. Kemampuannya untuk mengidentifikasi berbagai pola yang mungkin luput dari pengamatan pengguna, mengurangi bias kognitif, dan beradaptasi terhadap berbagai perubahan telah membuatnya menjadi pilar penting dalam lingkungan proyek digital modern. Sebagaimana ditunjukkan oleh Handaya et al. (2024), penggunaan model *hybrid* dalam *machine learning*, seperti dalam analisis sentimen

terhadap ujaran kebencian pasca pemilu 2024, mampu meningkatkan akurasi klasifikasi dengan menggabungkan kekuatan dari berbagai algoritma. Ini membuktikan bahwa pendekatan *machine learning* yang adaptif dan terintegrasi dapat memberikan hasil yang lebih optimal dalam konteks data dinamis dan kompleks.

2.3.1 Prinsip dan Kategori Utama

Machine learning beroperasi berdasarkan beberapa prinsip utama yang menentukan bagaimana algoritma akan mempelajari data yang diterima dan mengoptimalkan untuk menentukan hasil berdasarkan metode yang ditentukan. Prinsip-prinsip ini terkait erat dengan jenis data yang disediakan, hasil yang diinginkan, dan kompleksitas masalah.



Gambar 2-4 Kategori Utama pada *Machine Learning*

- *Supervised Learning*

Supervised learning adalah kategori metode *machine learning* yang paling banyak digunakan dan melibatkan pelatihan algoritma pada dataset berlabel. Setiap contoh dalam dataset berisi variabel input (fitur) dan label *output* yang terkait (variabel target). Algoritma belajar untuk memetakan *input* ke *output* dan kemudian dapat digunakan untuk membuat prediksi pada data yang tidak terlihat. Alnuaimi & Albaldawi (2024) menggambarkan *supervised learning* sebagai hal yang signifikan untuk tugas-tugas seperti klasifikasi status proyek, estimasi sumber daya, atau prediksi kesalahan dalam rekayasa perangkat lunak.

Algoritma dalam kategori ini meliputi:

- *Linear and logistic regression*
- *Decision Trees*
- *Random Forest*
- *Support Vector Machines (SVM)*
- *Gradient Boosting Machines (contoh: XGBoost, LightGBM)*
- *Artificial Neural Networks*

Model-model ini banyak digunakan dalam konteks manajemen proyek di mana data historis proyek tersedia untuk digunakan dalam metode pembelajaran misalnya, memprediksi apakah sebuah proyek akan selesai tepat waktu berdasarkan ukuran tim, jenis proyek, anggaran, dan lapisan teknologi.

- *Unsupervised Learning*

Unsupervised learning digunakan untuk data yang tidak memiliki output berlabel. Tujuannya adalah untuk menemukan pola, pengelompokan, atau struktur yang tersembunyi di dalam data. Pengelompokan dan pengurangan dimensi adalah teknik yang umum digunakan. Algoritma meliputi:

- *K-Means Clustering*
- *Hierarchical Clustering*
- *Principal Component Analysis (PCA)*

Raj & Dutta (2023) menyebutkan bahwa pendekatan unsupervised dapat digunakan untuk mengidentifikasi pola keterkaitan antar entitas tanpa label eksplisit. Ketika diterapkan dalam konteks proyek, pendekatan ini dapat dimanfaatkan untuk mengelompokkan stakeholder berdasarkan perilaku komunikasi dan intensitas keterlibatannya, sehingga memungkinkan sistem menyusun strategi komunikasi yang lebih tepat sasaran.

- *Reinforcement Learning*

Reinforcement learning adalah suatu paradigma pembelajaran yang diarahkan pada tujuan, di mana algoritma *machine learning* belajar melalui interaksi dengan lingkungan dan menerima umpan balik dalam bentuk penghargaan atau hukuman atas setiap tindakan yang dilakukan. Pendekatan ini sangat efektif dalam menyelesaikan masalah pengambilan keputusan berurutan, di mana keputusan saat ini dapat mempengaruhi keadaan dan hasil di masa depan.

Dalam konteks proyek, meskipun penerapannya masih terbatas, *reinforcement learning* menunjukkan potensi yang besar dalam skenario seperti *rescheduling* adaptif dan alokasi sumber daya dinamis berdasarkan situasi yang terus berubah. Ray et al. (2021) menyatakan bahwa pembelajaran berbasis interaksi dan evaluasi berkelanjutan seperti *reinforcement learning* sangat cocok untuk diterapkan pada sistem terdistribusi dan lingkungan yang membutuhkan respons adaptif secara *real-time*, dua hal yang juga umum dalam manajemen proyek berskala kompleks.

- *Other Learning Paradigms*

Beberapa paradigma pendukung lainnya yaitu metode yang menggabungkan data berlabel dan tidak berlabel untuk melatih model, yaitu:

- *Semi-supervised Learning*

Semi-supervised learning merupakan pendekatan *machine learning* yang memanfaatkan kombinasi antara data berlabel dan tidak berlabel dalam proses pelatihan model. Pendekatan ini menjadi sangat berguna ketika data berlabel tersedia dalam jumlah terbatas, namun terdapat banyak data tidak berlabel yang dapat dieksplorasi. Dengan menggabungkan kekuatan *supervised learning* yang bergantung pada anotasi manusia, dan *unsupervised learning* yang mengeksplorasi struktur data secara mandiri, *semi-supervised learning* dapat meningkatkan akurasi model tanpa memerlukan pelabelan data yang mahal dan memakan waktu. Fan (2022) menjelaskan bahwa dalam pengklasifikasian fitur proyek, penggunaan data tidak berlabel yang dikombinasikan dengan subset data berlabel mampu meningkatkan kinerja model klasifikasi secara signifikan. Pendekatan ini sangat relevan untuk aplikasi dalam manajemen proyek, terutama pada kasus seperti deteksi anomali tugas, klasifikasi dokumen proyek, atau pemetaan progres berdasarkan data parsial.

- *Self-supervised Learning*

Pembelajaran yang diawasi sendiri adalah paradigma *machine learning* di mana model belajar dari data yang tidak berlabel dengan menciptakan indikator penilaian mereka sendiri atau *pretext task*. Dibanding dengan mengandalkan label yang disediakan pengguna, model ini menggunakan informasi di dalam data itu sendiri untuk menghasilkan label, sehingga memungkinkannya untuk mempelajari berbagai representasi yang berguna tanpa pengawasan secara eksplisit (Raj & Dutta, 2023).

- *Federated Learning*

Federated learning adalah pendekatan *machine learning* terdesentralisasi di mana beberapa pengguna secara kolaboratif melatih sebuah model tanpa berbagi data mentah. Setiap pengguna melatih model lokal menggunakan datanya sendiri, dan selanjutnya hanya pembaruan model (atau parameter) yang dibagikan ke *server* pusat (atau agregator). Server ini menggabungkan semua pembaruan untuk menyempurnakan model global, guna memastikan privasi dan keamanan data (Ray et al., 2021).

Secara keseluruhan, semua prinsip ini akan memungkinkan metode pembelajaran untuk melakukan adaptasi terhadap berbagai macam kondisi data sekaligus mendukung berbagai macam tugas analisis dan pengambilan keputusan yang semakin kompleks.

2.3.2 Penerapan dalam *Project Management*

Machine learning telah menciptakan sebuah perubahan paradigma tentang cara bagaimana proyek dimulai, direncanakan, dieksekusi, dan dipantau. Secara konvensional, manajer proyek mengandalkan alat bantu seperti *Gantt chart*, *critical path analysis*, dan *expert judgement* untuk mengambil keputusan. Meskipun metode-metode ini masih bermanfaat, namun sering kali metode-metode ini kurang sesuai dengan besarnya skala, kecepatan, dan kompleksitas berbagai proyek yang ada saat ini. *machine learning* dapat menjembatani kesenjangan ini dengan memungkinkan adanya prediksi berdasarkan data, pembelajaran berkelanjutan, dan adaptasi yang dinamis.

- Estimasi waktu dan upaya

Estimasi waktu dan upaya yang akurat merupakan hal yang mendasar dalam perencanaan proyek. Metode konvensional seperti analisis *Function Point* dan estimasi ahli sering kali bersifat subjektif dan rentan terhadap kesalahan. Model *machine learning*, khususnya teknik model berbasis regresi, memungkinkan organisasi untuk memperkirakan upaya berdasarkan berbagai karakteristik, termasuk skala proyek, komposisi tim, dan kompleksitas teknis. Mamatha & Suma (2021) menemukan bahwa model *machine learning* secara signifikan mengurangi kesalahan pada saat melakukan estimasi dibandingkan dengan jika menggunakan pendekatan konvensional.

- Identifikasi dan Klasifikasi Risiko

Machine learning sangat baik dalam mengidentifikasi pola risiko di awal siklus proyek. Dengan melatih pengklasifikasi pada *database* risiko proyek historis, organisasi dapat mengidentifikasi proyek dengan tingkat potensi kegagalan yang tinggi. Fan (2022) menerapkan beberapa algoritma klasifikasi dan menemukan bahwa algoritma tersebut dapat membedakan secara akurat antara proyek pekerjaan berisiko tinggi dan berisiko rendah dengan karakteristik input yang terbatas.

- Rekayasa Kebutuhan

Pengumpulan dan penggolongan kebutuhan sangat penting untuk keberhasilan proyek, terutama dalam proyek perangkat lunak. Peninjauan secara manual terhadap dokumen persyaratan yang kompleks memakan waktu dan rentan terhadap kesalahan. Binkhonain & Zhao (2023) mempresentasikan *framework machine learning* untuk mengklasifikasikan

kebutuhan-kebutuhan perangkat lunak secara otomatis ke dalam beberapa kategori seperti fungsional, non-fungsional, dan arsitektural, sehingga dengan mengklasifikasikannya dapat mengurangi beban kognitif dan meningkatkan visibilitas.

- **Rekognisi Kegiatan dan Analisis Tenaga Kerja**

Di lingkungan proyek yang bersifat fisik seperti konstruksi atau manufaktur, penerapan *machine learning* yang dikombinasikan dengan data sensor (misalnya akselerometer, *wearable device*) membantu mengenali aktivitas tenaga kerja. Sanhudo et al. (2021) menggunakan pendekatan ini untuk mengidentifikasi aktivitas yang tidak produktif atau tidak efisien, sehingga memungkinkan adanya umpan balik secara *real-time* dan meningkatkan efisiensi di lokasi proyek.

- **Analisis Pemangku Kepentingan dan Tim**

Memahami berbagai dinamika tim dan pengaruh *stakeholder* sangat penting untuk komunikasi yang efektif dan memitigasi risiko. Mariani et al. (2023) menggunakan *unsupervised learning* untuk mengelompokkan pemangku kepentingan berdasarkan frekuensi interaksi dan pengaruhnya terhadap keputusan. Informasi ini mendukung penentuan prioritas *stakeholder* yang lebih baik dan penerapan strategi komunikasi yang tepat sasaran.

- **Manajemen Portofolio Proyek**

Dalam hal ini, model *machine learning* mendukung optimisasi portofolio proyek dengan memprediksi kombinasi proyek mana yang menghasilkan keuntungan terbaik, mengingat keterbatasan sumber daya. *Ensemble model* dan *neural network* sering sekali digunakan untuk melakukan evaluasi terhadap *trade-off* antara waktu, biaya, ruang lingkup, dan risiko.

2.3.3 Keuntungan *Machine Learning* dalam Pendukung Keputusan

Machine learning meningkatkan sistem pendukung keputusan (SPK) dengan mentransformasi mereka dari sebuah alat yang hanya bersifat reaktif menjadi sebuah asisten yang proaktif dan intuitif. Perubahan ini membawa beberapa manfaat:

- *Data-Driven Insights*

SPK konvensional sering kali mengandalkan sistem berbasis aturan atau dasbor statis. Di sisi lain, SPK yang mendukung penerapan *machine learning* dapat mengidentifikasi tren dan korelasi yang berkembang secara *real time*. Kemampuan dinamis ini memastikan bahwa keputusan didasarkan pada bukti terbaru (Rosett & Hagerty, 2021).

- *Real-Time Decision Support*

Dengan mengintegrasikan berbagai sumber data *real-time* (misalnya, sensor IoT, pelacak proyek), *Machine learning* juga dapat memberikan rekomendasi dan peringatan dengan cepat. Uddin et al. (2022) menyatakan bahwa *machine learning* merupakan pusat dari analitik proyek waktu nyata, yang memungkinkan pengambilan keputusan yang dapat beradaptasi dengan kondisi yang berubah-ubah.

- *Cognitive Augmentation*

Machine learning tidak dapat menggantikan penilaian manusia, melainkan melengkapinya. Dalam menangani pemrosesan dan pemodelan data yang sangat besar, *Machine learning* dapat membantu *project manager* lebih fokus pada pertimbangan strategik. Almarhabi & Yaghi (2025) mengungkapkan bahwa penggunaan teknologi *Machine learning* dapat meningkatkan kemampuan kognitif tim dengan memberikan saran berkualitas tinggi dan mengurangi kejenuhan dalam mengambil keputusan.

- *Forecasting and Scenario Planning*

Machine learning memiliki keunggulan dalam melakukan simulasi dan prediksi. Algoritma seperti *random forests* dan *neural networks* dapat memodelkan berbagai skenario dengan berbagai asumsi, sehingga membantu manajer merencanakan skenario terbaik, skenario terburuk, dan jalur proyek yang paling mungkin.

- *Enhanced Accuracy and Objectivity*

Kesalahan manusia, seperti kepercayaan diri yang berlebihan atau kecenderungan untuk berpihak, dapat mempengaruhi hasil keputusan proyek. Model *machine learning*, yang dilatih dengan beragam set data, mampu menawarkan rekomendasi yang lebih objektif dan konsisten. Seiring berjalannya waktu, model-model tersebut juga dapat disesuaikan berdasarkan umpan balik, sehingga dapat meningkatkan akurasi secara signifikan (Garg et al., 2022).

- *Automation of Repetitive Tasks*

Beberapa tugas seperti persetujuan *timesheet*, pengkategorian *requirement*, dan penilaian risiko dapat dilakukan secara otomatis dengan memanfaatkan teknologi *machine learning*, sehingga dapat mengurangi *workload* dan sekaligus meningkatkan efisiensi dan produktivitas.

2.3.4 Teknik *Machine Learning* dalam Manajemen Proyek

Masing-masing metode teknik *Machine learning* memiliki kelebihan yang dapat digunakan dalam berbagai tahapan di dalam siklus proyek. Berikut merupakan ulasan singkat terhadap beberapa algoritma yang banyak diterapkan:

Tabel 2-3 Teknik *Machine Learning* dan Contoh Penerapannya

Teknik	Kasus Penggunaan dalam Proyek	Referensi
<i>Decision Trees</i>	Klasifikasi risiko, penentuan stakeholder, prediksi keterlambatan	Fan (2022)
<i>Random Forests</i>	Alokasi sumber daya, signifikansi fitur untuk estimasi aktivitas	Binkhonain & Zhao (2023)
<i>Gradient Boosting</i>	Estimasi waktu dan biaya, prediksi skenario	Mahdi et al. (2021)
<i>Support Vector Machines</i>	Penggolongan tingkat keselamatan, identifikasi aktivitas konstruksi	Sanhudo et al. (2021)
<i>Naïve Bayes</i>	Pengelompokan dokumen persyaratan, kategorisasi pengajuan perubahan	Alnuaimi & Albaldawi (2024)
<i>K-Means Clustering</i>	Segmentasi <i>stakeholder</i> , pengelompokan performa anggota tim	Mariani et al. (2023)
<i>Neural Networks (ANN)</i>	Memprediksi <i>overrun budget</i> , identifikasi keterlambatan pada <i>sprint agile</i>	Uddin et al. (2022)


Selain itu, beberapa platform AutoML seperti Google AutoML dan H2O.ai memungkinkan pemilihan dan penyesuaian algoritma secara otomatis sehingga memberdayakan anggota tim proyek yang memiliki pengalaman ilmu statistik yang terbatas untuk membangun suatu model prediktif.

2.4 Deep Learning

Deep learning merupakan salah satu cabang dari pembelajaran mesin (*machine learning*) yang berfokus pada penggunaan jaringan saraf tiruan (*artificial neural networks*) dengan banyak lapisan tersembunyi atau biasa dikenal sebagai *deep neural networks*, untuk mempelajari representasi data secara hierarkis dan mengekstraksi pola-pola kompleks yang sulit ditangkap oleh algoritma konvensional. Dalam pendekatan ini, proses pembelajaran dilakukan secara otomatis melalui lapisan-lapisan transformasi *non-linear*, di mana setiap lapisan bertugas menyaring dan merepresentasikan fitur data dengan tingkat abstraksi yang semakin tinggi, sehingga sangat efektif untuk menganalisis data berukuran besar dan tidak terstruktur seperti gambar, suara, maupun teks.

Seiring dengan kemajuan komputasi dan ketersediaan data dalam jumlah besar, teknologi *deep learning* telah menjadi fondasi utama dalam berbagai aplikasi modern yang membutuhkan kemampuan analisis dan pengambilan keputusan cerdas, mulai dari sistem pengenalan wajah untuk keamanan, penerjemah bahasa

otomatis, hingga sistem rekomendasi dalam platform *e-commerce*. Tak hanya itu, teknologi ini juga memainkan peran penting dalam pengembangan sistem berbasis kecerdasan buatan yang mampu beradaptasi terhadap perubahan lingkungan secara *real-time*, seperti pada kendaraan otonom yang membutuhkan pemrosesan visual dan pengambilan keputusan cepat, maupun pada sistem pendukung keputusan berbasis data yang mengintegrasikan analisis prediktif dengan strategi bisnis Ahmed et al. (2023a).




Gambar 2-5 Perbandingan *Machine Learning* dan *Deep Learning*

Berbeda dengan *machine learning* tradisional yang masih bergantung pada fitur buatan manusia (*manual feature engineering*), *deep learning* mampu mengekstraksi fitur secara otomatis dari data mentah melalui proses hierarkis dalam jaringan *multi-layer*. Keunggulan utama *deep learning* terletak pada kemampuannya untuk belajar representasi data non-linear dan kompleks tanpa memerlukan pra-pemrosesan data secara intensif.

Walau demikian, keberhasilan model *deep learning* sangat dipengaruhi oleh kualitas arsitektur, volume data, strategi pelatihan, dan infrastruktur komputasi yang mendasarinya (Sharifani & Amini, 2023). Oleh karena itu, pemahaman terhadap arsitektur dan proses pelatihan menjadi aspek penting dalam penerapan *deep learning*.

2.4.1 Arsitektur *Deep Learning*

Arsitektur *deep learning* terdiri dari beberapa lapisan yaitu *input layer*, satu atau lebih *hidden layers*, dan *output layer*. Setiap lapisan terdiri dari sejumlah *neuron* yang saling terhubung, dan masing-masing *neuron* menerima *input*, mengalikannya dengan bobot tertentu, menambahkan bias, dan menerapkan fungsi aktivasi sebelum diteruskan ke lapisan berikutnya (Taye, 2023).



Gambar 2-6 Arsitektur *Deep Learning*

Fungsi aktivasi seperti ReLU (*Rectified Linear Unit*), Sigmoid, dan Tanh berperan penting dalam memperkenalkan non-linearitas ke dalam model. ReLU adalah fungsi aktivasi yang paling populer karena kesederhanaannya dan efisiensinya dalam mengatasi masalah *vanishing gradient* pada jaringan yang dalam Y. Dong (2025).


Seiring berkembangnya penelitian, banyak arsitektur lanjutan dikembangkan seperti *Convolutional Neural Networks* (CNN) untuk data spasial (misalnya gambar), *Recurrent Neural Networks* (RNN) untuk data berurutan (misalnya teks), serta arsitektur *transformer* dan variannya untuk menangani masalah dalam skala besar dan kompleksitas tinggi (Ahmed et al., 2023a).

Selain itu, terdapat pendekatan modern seperti *Deep Operator Networks* (DeepONets) yang memungkinkan pembelajaran langsung terhadap operator matematika kompleks dalam konteks sistem fisik dan teknik (Wang et al., 2022).

2.4.2 Mekanisme Training

Proses pelatihan model deep learning melibatkan dua fase utama yaitu *feedforward* dan *backpropagation* sehingga mekanisme ini memungkinkan model untuk secara bertahap meningkatkan akurasi dalam mengenali pola dan hubungan kompleks dalam data pelatihan. (Y. Dong, 2025).

- *Feedforward* adalah proses di mana input diproses dari lapisan pertama hingga lapisan terakhir untuk menghasilkan output prediksi.
- *Backpropagation* adalah mekanisme pembelajaran yang menghitung loss function, yaitu selisih antara prediksi dan nilai sebenarnya, kemudian menyebarkan error tersebut kembali ke seluruh jaringan untuk memperbarui bobot menggunakan algoritma optimisasi seperti Stochastic Gradient Descent (SGD) atau Adam Optimizer.



Gambar 2-7 Topologi *Feedforward - Backpropagation*

Proses pelatihan dilakukan dalam beberapa *epoch* (siklus penuh semua data pelatihan melalui model) dan *batch* (jumlah data yang diproses sekaligus dalam satu langkah *update* bobot).

Model *deep learning* sering kali mengalami masalah *overfitting* jika terlalu lama dilatih atau terlalu kompleks untuk dataset yang kecil. Oleh karena itu, diperlukan teknik regularisasi seperti *dropout*, *early stopping*, dan *L2 regularization* untuk menjaga generalisasi model (Ahmed et al., 2023a).

2.4.3 Tantangan Penerapan

Walaupun *deep learning* menawarkan keunggulan signifikan, implementasinya tidak terlepas dari sejumlah tantangan teknis dan praktis:

- **Kebutuhan Data Besar**
Deep learning memerlukan data dengan jumlah yang besar dan bervariasi agar mampu belajar representasi secara optimal. Jika data yang tersedia terbatas, maka model rentan terhadap *overfitting* (Serradilla et al., 2022).
- **Kebutuhan Komputasi Tinggi**
 Pelatihan model *deep learning*, terutama yang memiliki banyak lapisan dan parameter, membutuhkan sumber daya komputasi yang cukup tinggi seperti GPU atau TPU. Hal ini menjadikannya hambatan bagi organisasi menengah kebawah yang tidak memiliki infrastruktur memadai (Liu et al., 2024).

- Kompleksitas Implementasi dan Debugging

Banyak *framework deep learning* populer seperti TensorFlow dan PyTorch memiliki kompleksitas tinggi yang dapat menyulitkan implementasi dan *debugging*, terutama bagi pemula. Liu et al. (2024) menyatakan bahwa pemahaman mendalam tentang arsitektur *framework* dan *pipeline* pelatihan sangat penting untuk menghindari kesalahan implementasi yang sulit dideteksi.

- Distribusi dan Paralelisasi

Untuk pelatihan skala besar, proses pelatihan sering kali dilakukan secara paralel di beberapa node atau server. Ahmed et al. (2023a) menjelaskan bahwa meskipun distribusi data dan pelatihan secara paralel dapat mempercepat waktu pelatihan, hal ini juga memperkenalkan masalah baru seperti sinkronisasi parameter, *latency* jaringan, dan pembagian data yang optimal.


- Kesulitan Interpretabilitas

Deep learning dikenal sebagai “*black box*” karena sulit untuk memahami alasan di balik keputusan yang dibuat model. Ini menjadi tantangan khusus dalam sistem yang membutuhkan transparansi, seperti sistem pendukung keputusan dalam manajemen risiko proyek (Liu et al., 2024).

2.5 Hybrid Deep Learning

Hybrid Deep Learning adalah pendekatan yang menggabungkan dua atau lebih metode *deep learning* (atau kombinasi *deep learning* dan teknik lain) dengan tujuan mengatasi keterbatasan masing-masing model dan meningkatkan kinerja secara keseluruhan. Dalam era data besar dan kompleksitas aplikasi digital yang tinggi, pendekatan ini menjadi semakin penting karena satu jenis arsitektur atau algoritma sering kali tidak cukup untuk menangani seluruh aspek dari sebuah permasalahan secara optimal (Ahmed et al., 2023b).

Hybrid deep learning memanfaatkan kekuatan dari berbagai model pembelajaran mendalam dengan menggabungkan keunggulan arsitektur jaringan, strategi pelatihan, dan teknik ekstraksi fitur untuk membentuk sistem yang lebih fleksibel, tangguh, dan presisi. Misalnya, dalam *domain* pengenalan pola visual, penggabungan antara *Convolutional Neural Network* (CNN) dan *Long Short-Term Memory* (LSTM) terbukti mampu menangkap informasi spasial dari citra dan hubungan temporal dari urutan data. Menurut Jena et al. (2021), pendekatan hibrida semacam ini mampu meningkatkan akurasi klasifikasi citra medis secara signifikan karena kemampuan setiap arsitektur saling melengkapi dalam memahami struktur data kompleks.



Gambar 2-8 Diagram Alir *Hybrid Deep Learning*

Penggunaan pendekatan *hybrid* telah diterapkan secara luas dalam berbagai *domain*, seperti pengenalan emosi, analisis sentimen, deteksi serangan siber, sistem rekomendasi, hingga klasifikasi sinyal otak. Studi oleh Bavarchee (2024) menunjukkan bahwa kombinasi arsitektur dalam model *hybrid* dapat mengoptimalkan performa sistem dalam klasifikasi pola kompleks pada sistem partikel. Selain itu, Popoola et al. (2021) berhasil mengimplementasikan *hybrid deep learning* untuk mendeteksi serangan *botnet* dalam jaringan *Internet of Things* (IoT), sedangkan Tan et al. (2022) membuktikan efektivitasnya dalam analisis sentimen berbasis teks. Pendekatan ini secara konsisten terbukti meningkatkan akurasi, stabilitas, dan kemampuan generalisasi model di berbagai domain aplikasi.

2.5.1 Strategi Penggabungan Model

Strategi penggabungan model dalam *hybrid deep learning* dapat diklasifikasikan menjadi beberapa pendekatan utama berdasarkan bagaimana dan di mana model-model tersebut digabungkan dalam pipeline pembelajaran.

- *Model-level Integration*

Pada pendekatan ini, dua atau lebih arsitektur *deep learning* digabungkan ke dalam satu sistem terpadu untuk membentuk *pipeline* prediktif yang lebih komprehensif. Sebagai contoh, *Convolutional Neural Network* (CNN) dapat digunakan untuk mengekstraksi fitur spasial dari citra, yang kemudian dikombinasikan dengan *Long Short-Term Memory* (LSTM) guna menangani informasi sekuensial atau temporal. Menurut Jena et al. (2021), integrasi ini terbukti efektif dalam meningkatkan performa klasifikasi citra medis karena dapat menggabungkan kekuatan representasi spasial dan temporal secara bersamaan. Strategi *model-level* integration ini sangat cocok digunakan pada data multimodal seperti video, teks yang

diiringi metadata, atau sinyal biosensor yang memiliki dimensi waktu dan visual secara bersamaan.

- *Ensemble-based Integration*

Ensemble adalah teknik yang menggabungkan hasil dari beberapa model untuk meningkatkan akurasi prediksi (Tan et al., 2022). Beberapa metode *ensemble* yang umum digunakan meliputi:

- *Bagging*, membentuk beberapa model independen dan menggabungkan hasilnya (misalnya *voting* atau *averaging*).
- *Boosting*, membentuk model secara berurutan di mana model berikutnya berfokus pada kesalahan model sebelumnya.
- *Stacking*, menggabungkan output dari beberapa model sebagai input ke model *meta-classifier*.

Pendekatan ensemble terbukti efektif dalam meningkatkan stabilitas model dan mengurangi variansi prediksi (Bayoudh, 2024).

- *Feature-level Fusion*

Pada Pada strategi ini, fitur yang dihasilkan dari berbagai model digabungkan sebelum dimasukkan ke dalam classifier akhir. Misalnya, CNN digunakan untuk mengekstraksi fitur visual, sedangkan *embedding* dari teks diambil melalui RNN. Gabungan fitur tersebut kemudian diklasifikasikan oleh layer *fully connected*. Strategi ini bermanfaat saat data memiliki berbagai tipe atau dimensi (Jena et al., 2021).

- *Decision-level Fusion*

Penggabungan dilakukan pada tingkat akhir keputusan, di mana masing-masing model independen menghasilkan prediksi secara terpisah, dan sistem kemudian menggabungkan hasil-hasil tersebut menggunakan mekanisme seperti *majority voting*, *average probability*, atau *confidence-based selection*. Pendekatan ini memiliki keunggulan dalam meningkatkan stabilitas dan ketahanan sistem, khususnya ketika menghadapi data yang bervariasi atau tidak konsisten. Menurut Tan et al. (2022), *decision-level fusion* terbukti efektif dalam skenario analisis sentimen, di mana berbagai model *deep learning* digabungkan untuk memperkuat klasifikasi berbasis opini. Pendekatan ini sangat cocok diterapkan pada sistem yang bersifat *real-time* atau *mission-critical*, seperti *monitoring* siber, prediksi bencana, atau evaluasi cepat dalam layanan publik berbasis AI.

Setiap pendekatan memiliki kelebihan dan tantangan masing-masing. Misalnya, *ensemble model* memiliki performa tinggi tetapi mahal secara komputasi, sedangkan *decision-level fusion* lebih sederhana tetapi bisa mengabaikan sinergi antar fitur.

2.5.2 Kategori dan Pendekatan dalam Hybrid Deep Learning

Secara umum, pendekatan dalam *hybrid deep learning* dapat diklasifikasikan dalam tiga kategori besar berdasarkan titik integrasi dan jenis teknik yang digunakan:

- *Hybridization of Deep Learning with Traditional ML Models*

Pendekatan ini menggabungkan *deep learning* dengan algoritma *machine learning* konvensional seperti *Support Vector Machine* (SVM), *Decision Tree*, atau *Naive Bayes*. Strategi ini sering digunakan ketika hasil dari *deep learning* digunakan sebagai representasi fitur yang kemudian diproses oleh model klasifikasi tradisional. Misalnya, CNN dapat digunakan untuk mengekstraksi fitur visual dari gambar atau sinyal, yang kemudian diklasifikasikan menggunakan SVM atau *Naive Bayes* untuk meningkatkan kecepatan dan interpretabilitas hasil akhir. Menurut Ahmed et al. (2023b), kombinasi ini bermanfaat dalam mengatasi keterbatasan masing-masing pendekatan, karena *deep learning* unggul dalam pembelajaran representasi fitur secara otomatis, sedangkan algoritma ML tradisional sering kali unggul dalam klasifikasi berbasis aturan dan kebutuhan komputasi yang lebih rendah. Selain itu, Toscani et al. (2025) mencatat bahwa pendekatan hibrida semacam ini juga umum digunakan dalam sistem deteksi kesalahan industri, karena memberikan keseimbangan antara akurasi dan transparansi model.

- *Multimodal Hybrid Deep Learning*

Digunakan ketika data berasal dari berbagai sumber atau modalitas (teks, gambar, audio, dll.). Misalnya, Bayoudh (2024) menjelaskan arsitektur *hybrid multimodal* di mana CNN digunakan untuk gambar, dan LSTM untuk teks, kemudian digabungkan dalam layer integrasi. Pendekatan ini penting dalam konteks sistem rekomendasi, analisis sentimen, dan asisten virtual.

- *Hybridization Across Learning Strategies*

Ini mencakup penggabungan pendekatan *supervised*, *unsupervised*, dan *reinforcement learning* dalam satu kerangka kerja. Contoh implementasinya adalah penggunaan *autoencoders* (*unsupervised*) untuk *feature compression*, yang kemudian digunakan dalam *supervised classifier*. Jena et al. (2021) mencatat bahwa pendekatan ini memungkinkan fleksibilitas dalam menangani data terbatas dan tidak terstruktur.

Dalam konteks sistem pendukung keputusan atau aplikasi prediktif berbasis proyek, pendekatan *hybrid deep learning* sangat potensial untuk memberikan hasil prediksi yang lebih stabil dan akurat. Integrasi berbagai model memungkinkan

sistem menangkap pola yang kompleks dan beragam dalam data proyek, baik yang bersifat kuantitatif maupun kualitatif.


Namun demikian, pengembangan *hybrid model* juga menuntut pemahaman mendalam tentang arsitektur masing-masing model, metode integrasi yang sesuai, serta evaluasi performa model secara menyeluruh. Seperti yang dijelaskan oleh Ahmed et al. (2023b), tantangan utama dari *hybrid deep learning* adalah kebutuhan komputasi yang besar, kompleksitas dalam tuning model, serta proses interpretasi yang lebih sulit dibanding model tunggal.

2.6 Algoritma dalam Penelitian

Dalam konteks pengembangan sistem berbasis kecerdasan buatan, khususnya dalam penerapan *machine learning* dan *deep learning*, pemilihan algoritma menjadi aspek yang fundamental. Berbagai jenis algoritma menawarkan pendekatan yang berbeda dalam mengenali pola dan mempelajari data. Setiap algoritma memiliki kekuatan serta batasan tertentu tergantung pada jenis data dan permasalahan yang dihadapi. Tiga algoritma yang menjadi fokus kajian dalam bagian ini adalah *Artificial Neural Network* (ANN), *Gradient Boosting*, dan *Naive Bayes*. Ketiganya banyak digunakan dalam tugas klasifikasi dan prediksi karena kemampuannya yang tinggi dalam menyesuaikan diri terhadap kompleksitas data.

2.6.1 Artificial Neural Network (ANN)

Artificial Neural Network (ANN) merupakan pendekatan penting dalam pembelajaran mesin modern, terutama dalam konteks deep learning. ANN dirancang untuk meniru sistem saraf biologis dalam memproses informasi, dan secara arsitektural disusun dalam bentuk layer-layer yang saling terhubung dan mampu melakukan transformasi non-linear terhadap data.



Gambar 2-9 Arsitektur Artificial Neural Network

Artificial Neural Network (ANN) memiliki kemampuan tinggi untuk mempelajari relasi yang kompleks dan nonlinear dari data berukuran besar dan tidak terstruktur. Keunggulan ini menjadikan ANN sebagai fondasi dari banyak aplikasi teknologi modern, mulai dari sistem rekomendasi, klasifikasi medis, hingga sistem pendukung keputusan dalam manajemen proyek. Kim et al. (2023) menekankan bahwa efisiensi pelatihan ANN yang ditingkatkan melalui metode optimisasi seperti three-term conjugate gradient telah memperluas implementasi ANN ke berbagai domain dengan performa yang lebih stabil. Selain itu, Mandava et al. (2024) menunjukkan bahwa ANN tetap menjadi baseline kuat dalam prediksi penyakit kronis, menunjukkan ketahanannya sebagai algoritma yang andal dalam lingkungan data dinamis.

- Struktur Jaringan

Struktur ANN terdiri dari tiga bagian utama yaitu *input layer*, *hidden layers*, dan *output layer*. *Input layer* menerima vektor fitur $x = [x_1, x_2, x_3, \dots, x_n]$, yang kemudian dikirimkan ke satu atau lebih *hidden layer* untuk diproses secara non-linear, sebelum akhirnya diolah oleh *output layer* menjadi hasil prediksi. Setiap *neuron* pada *hidden layer* melakukan transformasi matematis:

$$z_j = \sum_{i=1}^n \omega_{ij} x_i + b_j, \quad a_j = \phi(z_j)$$

Dimana:

- ω_{ij} adalah bobot penghubung dari *neuron* i ke j ,
- b_j adalah bias neuron,
- ϕ adalah fungsi aktivasi.

Fungsi aktivasi ϕ sangat penting karena memperkenalkan non-linearitas ke dalam jaringan. Tanpa fungsi ini, ANN hanya akan mempelajari fungsi linier, bahkan dengan banyak layer sekalipun. Beberapa fungsi aktivasi umum dan karakteristiknya ditampilkan pada berikut:

Tabel 2-4 Fungsi aktivasi umum dan karakteristiknya

Fungsi Aktivasi	Rumus	Karakteristik
ReLU	$\phi(z) = \max(0, z)$	Cepat dan efisien, umum pada <i>hidden layers</i>
Sigmoid	$\phi(z) = \frac{1}{1 + e^{-z}}$	Output 0–1, cocok untuk probabilitas biner
Tanh	$\phi(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	Output –1 hingga 1, <i>zero centered</i>

Kim et al. (2023) menjelaskan bahwa pemilihan fungsi aktivasi memiliki dampak signifikan terhadap stabilitas pelatihan dan akurasi prediksi pada jaringan saraf. Salah satu fungsi aktivasi yang paling banyak digunakan saat ini adalah *Rectified Linear Unit* (ReLU), karena mampu mengatasi masalah *vanishing gradient* dan menunjukkan performa yang konsisten dalam jaringan dalam (*deep networks*). Penggunaan ReLU juga disoroti sebagai salah satu faktor yang mempercepat konvergensi pelatihan tanpa menambah kompleksitas perhitungan secara signifikan.

- Algoritma Training

ANN dilatih menggunakan algoritma berbasis gradien yang bertujuan meminimalkan kesalahan antara prediksi $\hat{y}$ dan target y . Proses ini dilakukan dalam dua tahap yaitu *feedforward* dan *backpropagation*. Selama *feedforward*, *input* diproses ke arah *output* melalui semua *layer*. Setelah prediksi diperoleh, kesalahan dihitung menggunakan fungsi *loss*, dan disebarkan kembali ke belakang jaringan (*backpropagation*) untuk memperbarui bobot.

Untuk klasifikasi biner, fungsi *loss* yang umum adalah *Binary Cross Entropy* (BCE):

$$\mathcal{L}_{BCE}(y, \hat{y}) = -\frac{1}{N} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Sedangkan untuk regresi digunakan *Mean Squared Error* (MSE):

$$\mathcal{L}_{MSE}(y, \hat{y}) = \frac{1}{N} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Proses update bobot dilakukan menggunakan algoritma optimisasi, misalnya *Stochastic Gradient Descent* (SGD):

$$\omega_{ij}^{(t+1)} = \omega_{ij}^{(t)} - \eta \cdot \frac{\partial \mathcal{L}}{\partial \omega_{ij}}$$

Kim et al. (2023) mengusulkan penggunaan metode *Variable Three-Term Conjugate Gradient*, yang lebih cepat konvergen dibanding metode tradisional seperti SGD atau Adam, serta mengurangi osilasi bobot saat pelatihan berlangsung.

- Teknik Peningkatan Pelatihan dan Generalisasi

Meskipun pelatihan *Artificial Neural Network* (ANN) pada umumnya dilakukan menggunakan pendekatan gradien lokal, terdapat berbagai teknik tambahan yang dapat meningkatkan performa, khususnya ketika

dihadapkan pada data berskala besar, tidak seimbang, atau mengandung *noise* tinggi. Salah satu pendekatan tersebut adalah integrasi antara ANN dengan teknik *boosting* seperti AdaBoost. Dalam metode ini, bobot pada data pelatihan disesuaikan secara iteratif untuk memberi penekanan lebih pada observasi yang sulit diklasifikasikan, sehingga model ANN dapat memfokuskan pembelajarannya pada contoh yang kompleks. Malek et al. (2023) menunjukkan bahwa pendekatan semacam ini efektif dalam meningkatkan sensitivitas klasifikasi dan kemampuan generalisasi, terutama pada data dengan distribusi kelas yang tidak merata.

Selain *boosting*, pendekatan lain adalah penggunaan algoritma metaheuristik seperti *Genetic Algorithms* (GA) dan *Particle Swarm Optimization* (PSO). Teknik ini digunakan untuk mengoptimalkan bobot dan arsitektur jaringan. Chong et al. (2021) membuktikan bahwa metaheuristik dapat menghindari perangkap *local minima* yang umum terjadi pada pelatihan ANN dengan *landscape error* yang kompleks. Dalam konteks industri dan data teknis berskala besar, pendekatan ini terbukti meningkatkan stabilitas pelatihan dan hasil akhir.

- Teknik Peningkatan Pelatihan dan Generalisasi

Hasil prediksi ANN sangat bergantung pada fungsi aktivasi pada *output layer*. Untuk klasifikasi biner, fungsi sigmoid mengubah *output* menjadi probabilitas:

$$\hat{y} = \frac{1}{1 + e^{-z}}$$

Untuk klasifikasi multi-kelas, fungsi *softmax* digunakan:


$$P(y = k|x) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$$

Output ini memberikan probabilitas terklasifikasi untuk masing-masing kelas, bukan hanya label diskrit. Hal ini memungkinkan sistem untuk memberikan prediksi dengan *confidence level* yang jelas. Menurut Mandava et al. (2024), pendekatan probabilistik seperti ini sangat berguna dalam sistem pendukung keputusan berbasis risiko, di mana prediksi bukan hanya biner (risiko/tidak), tetapi juga berisi bobot keyakinan yang dapat memengaruhi prioritas atau kebijakan lanjutan.

2.6.2 Gradient Boosting

Gradient Boosting merupakan salah satu teknik *ensemble learning* yang paling efektif dan banyak digunakan dalam *machine learning* modern. Teknik ini bekerja dengan membangun model prediktif secara bertahap, di mana setiap model

baru difokuskan untuk memperbaiki kesalahan dari model sebelumnya. Berbeda dengan pendekatan seperti *bagging* yang membentuk model secara paralel, *boosting* bersifat sekuensial dan adaptif.



Gambar 2-10 Representasi Grafis *Gradient Boosting*

Gradient Boosting sangat cocok digunakan dalam berbagai masalah klasifikasi dan regresi karena mampu menangkap pola data yang kompleks, memperbaiki bias prediktif, dan menghasilkan performa akurasi yang tinggi (G. Bai & Chandra, 2023; Jun, 2021). Dalam subbab ini, akan dibahas konsep *boosting*, mekanisme perhitungan bobot kesalahan, proses pembentukan model, serta visualisasi alur kerja algoritmanya.

- Konsep *Boosting* dan *Iterative Learning*

Boosting merupakan pendekatan pembelajaran *ensemble* di mana sejumlah model lemah (*weak learners*) digabungkan untuk membentuk satu model kuat (*strong learner*). *Gradient Boosting* khususnya menggunakan regresi residual dalam bentuk turunan fungsi *loss* sebagai target pembelajaran untuk model-model berikutnya. Setiap model baru secara eksplisit dilatih untuk meminimalkan kesalahan dari gabungan model sebelumnya, menjadikan proses pembelajaran lebih akurat dari waktu ke waktu.

Secara umum, $F_m(x)$ jika adalah model pada iterasi ke- m , maka *boosting* bekerja sebagai berikut:

$$F_0(x) = \arg\min_{\gamma} \sum_{i=1}^N \mathcal{L}(y_i, \gamma)$$

$$F_m(x) = F_{m-1}(x) + \gamma_m h_m(x)$$

di mana:

- $h_m(x)$ adalah model regresi pada iterasi ke- m
- γ_m adalah learning rate atau koefisien pengali untuk memperkecil overfit.

Menurut G. Bai & Chandra (2023), pendekatan ini sangat efektif karena secara sistematis memperbaiki kelemahan prediktif dari model sebelumnya dengan memanfaatkan informasi gradien dari fungsi kerugian.

- Proses Perhitungan Bobot Kesalahan

Langkah penting dalam *Gradient Boosting* adalah menghitung *residual error* atau *pseudo-residual* dari prediksi sebelumnya. Dalam konteks fungsi kerugian diferensiabel seperti *Mean Squared Error* (MSE), residual dihitung sebagai:

$$r_i^{(m)} = y_i - F_{m-1}(x_i)$$

Namun, dalam implementasi umum *Gradient Boosting*, residual sering direpresentasikan sebagai gradien negatif dari fungsi loss terhadap prediksi sebelumnya:

$$r_i^{(m)} = \left[\frac{\partial \mathcal{L}(y_i, F(x_i))}{\partial F(x_i)} \right]$$


Model $h_m(x)$ dilatih untuk memprediksi nilai $r_i^{(m)}$, dan bobot optimal γ_m dicari dengan meminimalkan total loss:

$$\gamma_m = \arg\min_{\gamma} \sum_{i=1}^N \mathcal{L}(y_i, F_{m-1}(x_i) + \gamma h_m(x_i))$$

Malek et al. (2023) menekankan pentingnya tahap ini karena ia menjamin bahwa setiap model baru fokus pada bagian data yang paling banyak mengalami kesalahan, meningkatkan efisiensi pembelajaran secara bertahap.

- Alur Pembentukan Model *Boosting*

Gradient Boosting dimulai dari model prediktif sederhana, dan setiap iterasi model baru menambahkan koreksi terhadap kesalahan sebelumnya.



Gambar 2-11 Alur Pembentukan Model *Boosting*


Jun (2021) dalam studi pemodelan perubahan tata guna lahan menunjukkan bahwa *Gradient Boosting* mengungguli metode seperti *Random Forest* dan ANN dalam akurasi prediksi spasial, terutama karena kemampuannya yang iteratif dalam menangani bias model awal.

Tabel 2-5 Perbedaan antara Model Tunggal dan *Gradient Boosting*

Aspek	Model Tunggal	<i>Gradient Boosting</i>
Strategi Pelatihan	Sekali, langsung akhir	Iteratif, bertahap
Koreksi Kesalahan	Tidak ada	Ada, melalui residual atau gradien
Sensitivitas terhadap bias	Tinggi	Rendah, karena bias dikoreksi secara bertahap
Risiko overfitting	Menengah	Bisa tinggi jika tidak dikendalikan (tanpa pruning)

2.6.3 *Naive Bayes*

Naive Bayes adalah algoritma klasifikasi berbasis probabilistik yang didasarkan pada Teorema *Bayes*, dan dikenal karena kesederhanaan, efisiensi, serta efektivitasnya dalam menangani dataset besar dengan fitur-fitur yang bersifat diskrit atau kategorikal.



Gambar 2-12 Konsep *Naive Bayes*

Meskipun algoritma ini disebut "*naive*" karena mengasumsikan independensi antar fitur, sebuah asumsi yang sering kali tidak sepenuhnya terpenuhi dalam data dunia nyata, *Naive Bayes* tetap mampu menghasilkan performa klasifikasi yang kompetitif, bahkan ketika dibandingkan dengan algoritma *machine learning* yang lebih kompleks. Berrar (2025) menekankan bahwa kekuatan utama dari *Naive Bayes* terletak pada kesederhanaan, efisiensi komputasi, dan kestabilannya terhadap data berukuran besar. Selain itu, Bogdal et al. (2022) menunjukkan bahwa dalam konteks klasifikasi forensik, *Naive Bayes* dapat bersaing dengan algoritma seperti *Random Forest* dan *Gradient Boosting* dalam hal akurasi dan interpretabilitas. Model ini telah digunakan secara luas dalam berbagai aplikasi seperti klasifikasi dokumen, analisis sentimen, diagnosis medis, serta sistem rekomendasi awal yang membutuhkan respons cepat dan dapat dijelaskan.

- Konsep Dasar Teori *Bayes*

Teorema Bayes merupakan fondasi matematis dari *Naive Bayes*, yang menyatakan bahwa:

$$P(C_k|X) = \frac{P(X|C_k) \cdot P(C_k)}{P(X)}$$

di mana:

- $P(C_k|X)$ adalah Probabilitas kelas C_k terhadap fitur X (*posterior*),
- $P(C_k)$ adalah Probabilitas awal (*prior*) dari kelas C_k ,
- $P(X|C_k)$ adalah Likelihood (probabilitas fitur muncul jika diketahui kelas),
- $P(X)$ adalah Probabilitas fitur secara keseluruhan (*evidence*), biasanya diabaikan karena konstan untuk seluruh kelas.

Dalam praktik klasifikasi, nilai $P(X)$ sebagai probabilitas bukti (*evidence*) tidak perlu dihitung secara eksplisit karena nilainya konstan untuk semua kelas dan tidak memengaruhi perbandingan antar probabilitas kelas. Oleh karena itu, fokus perhitungan biasanya diarahkan pada $P(Y|X) \propto P(X|Y) \cdot P(Y)$. Wickramasinghe & Kalutarage (2021) menjelaskan bahwa pendekatan ini tetap efektif bahkan dalam kasus-kasus

klasifikasi berbasis atribut sederhana seperti kehadiran dan penilaian kinerja. Sebagai ilustrasi, *Naive Bayes* dapat digunakan untuk memprediksi apakah seorang dosen termasuk dalam kategori "teladan" berdasarkan histori kehadiran dan nilai evaluasi yang telah distandardisasi, dengan memanfaatkan data masa lalu untuk membangun probabilitas posterior.

- Asumsi Independensi Fitur

Keistimewaan (dan juga keterbatasan) utama dari *Naive Bayes* adalah asumsi bahwa semua fitur bersifat independen secara kondisional terhadap kelas. Artinya, setiap fitur tidak saling memengaruhi, sehingga probabilitas gabungan $P(X|C_k)$ dapat dinyatakan sebagai hasil perkalian sederhana:

$$P(X|C_k) = \prod_{i=1}^n P(x_i|C_k)$$

Dengan pendekatan probabilistik yang sederhana, model *Naive Bayes* sangat efisien secara komputasi dan cepat dalam pelatihan, bahkan saat digunakan pada dataset berskala besar. Wickramasinghe & Kalutarage (2021) mencatat bahwa efisiensi ini menjadikannya algoritma yang ideal untuk sistem *real-time* dan aplikasi dengan keterbatasan sumber daya komputasi. Selain itu, pendekatan *hybrid* antara *Naive Bayes* dan *Artificial Neural Network* (ANN) telah diteliti untuk meningkatkan proses pelatihan dan generalisasi model.

Sebagai contoh, Malek et al. (2023) menunjukkan bahwa integrasi teknik *boosting* dengan klasifikasi probabilistik pada data tidak seimbang mampu memperbaiki sensitivitas model secara signifikan. Dalam konteks ini, output probabilistik dari *Naive Bayes* juga dapat dimanfaatkan sebagai input awal atau bobot awal pada jaringan saraf, sehingga membantu mempercepat konvergensi ANN dan meningkatkan akurasi akhir pelatihan pada data yang kompleks.

- Rumus dan Contoh Perhitungan Klasifikasi

Untuk klasifikasi, *Naive Bayes* menghitung skor *posterior* untuk setiap kelas dan memilih kelas dengan skor tertinggi:

$$\hat{C} = \arg \max_{C_k} P(C_k) \cdot \prod_{i=1}^n P(x_i|C_k)$$

Misalnya ingin menentukan apakah suatu proyek termasuk kategori “Berisiko Tinggi” atau “Berisiko Rendah” berdasarkan dua fitur:

- Durasi Proyek > 12 bulan
- Biaya Proyek > 1 Miliar

Diketahui dari data historis:

- $P(R_T) = 0.4$, $P(\text{Durasi} > 12|R_T) = 0.9$, $P(\text{Biaya} > 1M|R_T) = 0.8$
- $P(R_R) = 0.6$, $P(\text{Durasi} > 12|R_T) = 0.3$, $P(\text{Biaya} > 1M|R_T) = 0.2$

Perhitungan probabilitas *posterior*:

$$P(R_T|data) \propto 0.4 \cdot 0.9 \cdot 0.8 = 0.288$$

$$P(R_R|data) \propto 0.6 \cdot 0.3 \cdot 0.2 = 0.036$$

Karena $0.288 > 0.036$, maka proyek diklasifikasikan sebagai Risiko Tinggi.

Pendekatan *Naive Bayes* terbukti sangat efektif dalam klasifikasi berbasis kriteria tetap atau atribut yang terdefinisi jelas, seperti klasifikasi jenis objek, pengelompokan dokumen, atau pemilihan kategori performa dalam sistem berbasis aturan. Berrar (2025) menekankan bahwa model ini ideal untuk *domain* dengan fitur-fitur diskrit yang saling bebas secara asumsi, serta ketika interpretabilitas dan efisiensi proses klasifikasi menjadi prioritas utama. Kemampuan *Naive Bayes* dalam menangani data kategorikal dengan kecepatan tinggi menjadikannya pilihan populer dalam sistem berbasis penilaian atau klasifikasi prosedural.

Salah satu kekuatan utama dari algoritma *Naive Bayes* terletak pada kesederhanaan implementasinya serta kecepatan tinggi baik dalam proses pelatihan maupun prediksi. Tidak seperti model lain seperti *Artificial Neural Network* (ANN) atau *Gradient Boosting* yang memerlukan proses optimisasi gradien dan iterasi berulang, *Naive Bayes* hanya memerlukan estimasi probabilitas bersyarat antara fitur dan kelas. Hal ini menjadikannya sangat efisien dalam lingkungan sistem pendukung keputusan, khususnya pada tahap awal pengembangan atau sebagai *baseline model* untuk evaluasi klasifikasi awal. Wickramasinghe & Kalutarage (2021) menegaskan bahwa keunggulan komputasional ini menjadikan *Naive Bayes* sangat sesuai digunakan dalam aplikasi *real-time* atau sistem yang memiliki keterbatasan sumber daya.

Selain efisiensi, kemudahan interpretasi juga menjadi nilai tambah dari *Naive Bayes*. Model ini memberikan probabilitas eksplisit untuk setiap keputusan, sehingga memudahkan pengguna non-teknis untuk memahami alasan di balik klasifikasi yang dilakukan sistem. Berrar (2025) menyatakan bahwa transparansi model *Naive Bayes* menjadi keunggulan signifikan dalam aplikasi seperti evaluasi kinerja pegawai, sistem rekomendasi, maupun klasifikasi berbasis kebijakan organisasi. Misalnya, dalam sistem pendukung keputusan berbasis penilaian

karyawan atau dosen, pengguna dapat langsung melihat bahwa kategori “berkinerja tinggi” ditetapkan karena memiliki nilai probabilitas tertinggi untuk indikator kehadiran dan kualitas evaluasi, berdasarkan distribusi data historis.

2.7 Tools dan Programming

Dalam pengembangan sistem pendukung keputusan berbasis *hybrid machine learning* untuk optimalisasi alokasi sumber daya dan manajemen risiko proyek, pemilihan *tools*, *framework*, serta bahasa pemrograman memainkan peran strategis. Kesesuaian teknologi yang digunakan tidak hanya berkaitan dengan kebutuhan teknis, seperti kecepatan komputasi, skalabilitas, dan modularitas arsitektur, tetapi juga mempertimbangkan aspek integrasi model *machine learning* secara efisien dan *real-time* dalam konteks aplikasi berbasis *web*. Oleh karena itu, sistem ini dirancang dengan kombinasi antara *framework web* yang stabil (Laravel), *runtime server-side* berbasis JavaScript (Node.js), dan pustaka pembelajaran mesin seperti TensorFlow.js dan Brain.js. Kombinasi ini mendukung fleksibilitas integrasi antara *backend* dan *engine* pembelajaran, serta efisiensi komputasi melalui pemrosesan *client-side* dan *server-side* secara simultan. Menurut Goh et al. (2022), pemanfaatan teknologi *deep learning* dalam aplikasi web memungkinkan integrasi *machine learning* secara native di sisi klien untuk kecepatan inferensi tinggi. Selain itu, KletzSabrina et al. (2021) menyoroti bagaimana pustaka seperti TensorFlow.js memungkinkan *deployment model* AI langsung di *browser* tanpa perlu *server* komputasi berat, sehingga cocok untuk sistem *hybrid* yang mendukung pengambilan keputusan dinamis.

2.7.1 Framework dan Bahasa Pemrograman

- JavaScript

JavaScript merupakan bahasa pemrograman inti dalam sistem ini, digunakan pada sisi *client* maupun *server*. Bahasa ini memiliki ekosistem yang luas dan fleksibel, mendukung integrasi dengan berbagai *library machine learning* yang berjalan langsung di *browser* ataupun di *server* menggunakan Node.js. JavaScript tidak hanya digunakan untuk membangun antarmuka pengguna yang interaktif, tetapi juga untuk melakukan *pre-processing* data, komunikasi API, dan menjalankan model prediktif secara langsung.



Gambar 2-13 Logo JavaScript

Menurut Goh et al. (2022), penggunaan JavaScript dalam pengembangan *deep learning* berbasis web membuka peluang untuk mengurangi ketergantungan pada server eksternal, memungkinkan pelatihan dan inferensi dilakukan langsung di sisi *client* melalui *browser*. Hal ini sejalan dengan pendekatan arsitektural sistem ini, di mana sebagian proses prediksi dijalankan di *browser* (menggunakan TensorFlow.js atau Brain.js), sedangkan Laravel bertugas menangani validasi dan logika bisnis.

Lebih lanjut, dalam konteks pengembangan sistem yang aman dan terstruktur, penting untuk mempertimbangkan aspek keamanan dalam penggunaan JavaScript, khususnya di sisi *server-side* dengan Node.js. Brito et al. (2023) menyoroti bahwa kerentanan pada paket-paket Node.js sering kali disebabkan oleh kurangnya penerapan analisis statis secara menyeluruh terhadap dependensi JavaScript. Hal ini memungkinkan terjadinya eksploitasi seperti injeksi skrip, *remote code execution* (RCE), atau penyalahgunaan *library* pihak ketiga yang tidak tersanitasi dengan baik. Oleh karena itu, pengembangan sistem yang mengandalkan Node.js harus memperhatikan praktik sanitasi *input*, pembatasan hak akses eksekusi, dan manajemen dependensi secara ketat untuk menjaga integritas sistem.

- Node.js

Node.js merupakan *runtime environment* berbasis *event-driven* yang memungkinkan JavaScript berjalan di sisi *server*. Dalam sistem ini, Node.js digunakan sebagai penghubung antara model *machine learning* yang ditulis dalam JavaScript dan backend aplikasi web yang dibangun dengan Laravel. Keunggulan Node.js terletak pada efisiensinya dalam menangani proses asinkron dan *IO-bound*, sehingga cocok digunakan dalam sistem yang memerlukan eksekusi prediksi secara *real-time*.



Gambar 2-14 Logo Node.js

Node.js dikenal sebagai *platform runtime server-side* yang unggul dalam membangun sistem jaringan berkinerja tinggi berkat arsitektur *event-loop* yang bersifat *non-blocking* dan *asynchronous*. Keunggulan ini membuatnya sangat cocok untuk mengembangkan aplikasi *real-time* sekaligus mendukung integrasi pustaka-pustaka *machine learning* berbasis JavaScript. Brito et al. (2023) mencatat bahwa ekosistem Node.js menawarkan fleksibilitas tinggi dalam integrasi dengan pustaka AI, namun tetap menyimpan tantangan besar dalam aspek keamanan. Salah satu perhatian utama adalah potensi *server-side JavaScript injection*, yang dapat dimanfaatkan untuk mengeksploitasi input tak tersanitasi. Untuk mengatasi hal ini, Ntantogian et al. (2021) mengembangkan *framework* NodeXP sebagai alat untuk mendeteksi dan mengeksplorasi celah eksploitasi dalam aplikasi Node.js, sekaligus menekankan pentingnya pengelolaan *input* secara aman terutama dalam konteks pemrosesan data oleh pustaka *machine learning*.

- Laravel

Laravel merupakan *framework* PHP modern berbasis arsitektur *Model-View-Controller* (MVC), yang berperan sebagai *backend* utama dalam sistem ini. Laravel bertanggung jawab dalam mengatur autentikasi pengguna, *routing*, *middleware* keamanan, pengelolaan sesi, serta penyediaan REST API untuk komunikasi antara front-end dan engine prediksi di sisi *server*. Framework ini dipilih karena kestabilannya, dokumentasi yang kuat, dan kemampuan integrasinya dengan sistem eksternal melalui API atau event broadcasting.



Gambar 2-15 Logo Laravel

Dalam implementasi sistem, Laravel menerima *input* pengguna (misalnya parameter proyek), kemudian meneruskan data tersebut ke *engine*

machine learning berbasis Node.js, lalu mengambil hasil prediksi dan menyajikannya ke antarmuka pengguna. Dengan pola komunikasi ini, Laravel berperan sebagai "*orchestrator*" antara lapisan presentasi dan layer kecerdasan buatan. Menurut Goh et al. (2022), pola integrasi semacam ini umum digunakan dalam arsitektur aplikasi berbasis *web* modern, di mana *backend* konvensional bertindak sebagai penghubung antara *frontend* dan *engine* AI yang berjalan secara independen, baik di server maupun langsung di *browser*. Pendekatan ini mendukung pemrosesan paralel dan respons yang efisien pada sistem berbasis *machine learning*.

2.7.2 Library dan Tools Pendukung

- TensorFlow.js

TensorFlow.js merupakan pustaka *open-source* dari Google yang memungkinkan pelatihan dan inferensi model *machine learning* dalam JavaScript. Pustaka ini menyediakan API yang fleksibel dan powerful untuk membangun berbagai jenis *neural network*, termasuk *convolutional neural network* (CNN), *recurrent neural network* (RNN), dan *feedforward network*. TensorFlow.js dapat dijalankan baik di *browser* maupun di Node.js, mendukung pelatihan model secara *real-time* maupun pemanggilan model yang telah dilatih sebelumnya dalam format JSON.



Gambar 2-16 Logo TensorFlow

TensorFlow.js merupakan pustaka pembelajaran mesin berbasis JavaScript yang dirancang untuk menjalankan model secara langsung di *browser* maupun lingkungan *server-side* seperti Node.js. Goh et al. (2022) menyatakan bahwa TensorFlow.js memungkinkan model yang awalnya dikembangkan menggunakan TensorFlow di Python untuk dikonversi ke dalam format yang kompatibel dengan JavaScript, sehingga dapat digunakan secara efisien dalam aplikasi web interaktif. Hal ini memungkinkan integrasi *machine learning* secara *native* di *browser* tanpa ketergantungan pada komunikasi server intensif, menjadikannya ideal untuk sistem pendukung keputusan yang membutuhkan prediksi *real-time* dengan latensi rendah.

Lebih lanjut, Guerra Pires (2023) dalam penelitiannya menunjukkan bahwa penggunaan TensorFlow.js dalam interpretasi dataset biomedis memungkinkan *deployment model* AI langsung ke sisi klien, sehingga pengguna dapat berinteraksi dengan model secara langsung tanpa pengolahan tambahan dari *server*. Salah satu keunggulan teknis dari TensorFlow.js adalah kemampuannya memanfaatkan GPU acceleration melalui WebGL, yang mempercepat proses inferensi dan mendukung pengolahan paralel di *browser*. KletzSabrina et al. (2021) juga menekankan bahwa dengan dukungan ini, pustaka TensorFlow.js menjadi salah satu solusi andal untuk menjalankan *deep learning* langsung di browser, termasuk untuk skenario *hybrid machine learning* yang membutuhkan efisiensi tinggi dan keterlibatan pengguna secara langsung.

- Brain.js

Brain.js merupakan pustaka *neural network* ringan yang sepenuhnya ditulis dalam JavaScript. *Library* ini menawarkan antarmuka sederhana untuk membangun dan melatih model seperti *Feedforward Neural Networks* (FFNN) dan *Recurrent Neural Networks* (RNN), dengan dukungan proses pelatihan dan inferensi baik di *browser* maupun lingkungan Node.js. Karena sifatnya yang ringan dan mudah diimplementasikan, Brain.js sangat ideal digunakan untuk kebutuhan klasifikasi cepat, seperti identifikasi proyek berisiko atau pengalokasian kategori sumber daya secara *real-time* dalam sistem pendukung keputusan berbasis web.



Gambar 2-17 Logo Brain.js

KletzSabrina et al. (2021) mengidentifikasi Brain.js sebagai bagian dari tren “*deep learning in the browser*,” yang memungkinkan integrasi kecerdasan buatan langsung dalam antarmuka pengguna tanpa harus menunggu respons dari *server*. Suryadevara (2021) juga menambahkan bahwa pustaka seperti Brain.js memberikan kecepatan inferensi tinggi dan jejak memori (*footprint*) yang kecil, menjadikannya cocok untuk prototipe

cepat maupun aplikasi produksi ringan yang tidak membutuhkan arsitektur model dalam yang kompleks.

- Integrasi Sistem dan Keamanan

Integrasi seluruh *tools* dalam sistem dilakukan dengan pendekatan modular dan terdistribusi. Laravel berfungsi sebagai pengelola antarmuka pengguna serta alur data aplikasi, sementara Node.js menjalankan *engine* pembelajaran mesin sebagai bagian dari *back-end* yang terisolasi. TensorFlow.js dan Brain.js digunakan untuk membangun serta menjalankan model prediktif, baik di sisi *server* maupun di dalam *browser*. Proses komunikasi antar komponen dilakukan melalui protokol REST API, dengan struktur *input-output* yang konsisten untuk menjamin interoperabilitas. Untuk menjamin keamanan sistem, validasi input diterapkan di sisi Laravel guna mencegah eksploitasi terhadap *engine machine learning* di Node.js, mengingat potensi kerentanannya terhadap serangan seperti JavaScript *injection*. Brito et al. (2023) menekankan bahwa sistem berbasis Node.js cenderung memiliki celah keamanan jika tidak dikombinasikan dengan mekanisme sanitasi dan kontrol dependensi yang kuat.

Lebih lanjut, Suryadevara (2021) menyebut bahwa arsitektur seperti ini, di mana komputasi AI dilakukan secara langsung di dalam *browser* atau server ringan, menawarkan fleksibilitas tinggi dalam hal *deployment* dan efisiensi penggunaan sumber daya. Hal ini menjadikan model *hybrid* yang dijalankan secara modular sangat cocok untuk pengembangan sistem pendukung keputusan yang dinamis dan mudah diakses tanpa infrastruktur berat.

2.8 Alokasi Sumber Daya dalam Proyek

Alokasi sumber daya merupakan inti dari proses manajemen proyek yang efektif. Dalam konteks proyek teknologi informasi dan pengembangan perangkat lunak, pengalokasian sumber daya mencakup lebih dari sekadar distribusi personel atau penjadwalan tugas, melainkan sebuah sistem dinamis yang menggabungkan keterbatasan waktu, kapasitas manusia, dan prioritas proyek yang berubah-ubah. Aratovskyi & Liubchenko (2024) menyebut bahwa permasalahan alokasi sumber daya menjadi semakin kompleks pada organisasi yang menjalankan beberapa proyek secara paralel (*multi-project environment*), di mana konflik prioritas dan keterbatasan sumber daya menjadi hambatan utama keberhasilan proyek.

2.8.1 Komponen Sumber Daya

Dalam proyek pengembangan perangkat lunak, sumber daya tidak hanya terbatas pada tenaga kerja, tetapi juga mencakup berbagai elemen teknis dan non-teknis yang saling terkait. L. Bai et al. (2024b) mengelompokkan komponen sumber daya menjadi beberapa domain utama, yaitu manusia, waktu, dan infrastruktur,

yang semuanya memainkan peran krusial dalam keberhasilan manajemen proyek. Masing-masing domain memiliki karakteristik dan tantangan alokasi tersendiri, terutama dalam lingkungan multi-proyek yang kompleks dan saling tumpang tindih. Kesesuaian alokasi terhadap kapasitas aktual, ketersediaan sumber daya, dan prioritas proyek menjadi hal penting dalam pengambilan keputusan yang efektif.

Tabel 2-6 Komponen Sumber Daya dalam Proyek TI

Kategori	Komponen	Keterangan
Sumber Daya Manusia	<i>Developer, UI/UX Designer, QA, Project Manager</i>	Kebutuhan utama untuk eksekusi teknis proyek
Waktu Kerja	Durasi tugas, jam kerja, deadline	Mempengaruhi estimasi kapasitas dan urutan pengerjaan
Infrastruktur	<i>Server, software tools, lisensi</i>	Sumber daya pendukung teknis yang terbatas atau berbasis lisensi

Chiang & Lin (2020) menambahkan bahwa pemanfaatan sumber daya manusia menjadi aspek yang paling krusial, sebab dalam pengembangan perangkat lunak, performa individu sangat menentukan kualitas keluaran. Selain itu, alokasi waktu yang tidak realistis dapat menyebabkan penumpukan beban kerja dan burnout yang berdampak negatif pada produktivitas tim.

2.8.2 Permasalahan Umum

Masalah alokasi sumber daya dalam proyek TI sangat erat kaitannya dengan keterbatasan kapasitas, konflik antar prioritas proyek, serta ketidakpastian jadwal. Dalam konteks multi-proyek, sering kali individu atau perangkat yang sama diminta untuk menyelesaikan tugas dari beberapa proyek sekaligus secara paralel. Situasi ini menciptakan tekanan sumber daya dan menimbulkan gangguan produktivitas lintas proyek. Aratovskyi & Liubchenko (2024) menyebut fenomena ini sebagai karakteristik umum dalam manajemen multi-proyek, di mana jumlah proyek aktif sering melebihi jumlah sumber daya yang tersedia secara realistis. Kondisi ini menciptakan efek *bottleneck*, memperbesar risiko keterlambatan, kesalahan estimasi beban kerja, dan menurunkan efisiensi manajemen secara keseluruhan.

Tabel 2-7 Permasalahan Umum dalam Alokasi Sumber Daya

Permasalahan	Penjelasan
<i>Over-allocation</i>	Sumber daya ditugaskan ke beberapa aktivitas melebihi kapasitas waktu
<i>Bottleneck Personil</i>	Individu spesialis yang terlalu banyak menangani tugas kritis
<i>Switching Cost</i>	Penurunan produktivitas akibat pindah fokus antar proyek atau tugas

Ketidaksinkronan Jadwal	Jadwal antar proyek yang saling bertabrakan
Konflik Prioritas	Tidak adanya sistem penetapan urgensi secara objektif antar proyek

L. Bai et al. (2024b) dalam studi mereka menunjukkan bahwa penjadwalan manual dalam portofolio proyek tanpa pendekatan prediktif atau simulatif menghasilkan deviasi penyelesaian hingga 25% lebih lambat dibanding pendekatan berbasis simulasi *hybrid*. Demikian juga, Chilton (2022) menunjukkan bahwa kurangnya fleksibilitas alokasi waktu menyebabkan tidak optimalnya utilisasi personil, terutama pada proyek yang mengalami perubahan *scope* secara dinamis.

2.8.3 Strategi Optimasi

Untuk mengatasi permasalahan tersebut, berbagai pendekatan optimasi telah dikembangkan, mulai dari metode manual berbasis heuristik, pemodelan matematis, hingga teknik *hybrid* berbasis pembelajaran mesin. Setiap pendekatan memiliki kelebihan dan keterbatasan tergantung kompleksitas proyek, skala organisasi, dan ketersediaan data historis.

- Pendekatan Manual dan Heuristik

Manajer proyek umumnya menggunakan pendekatan heuristik berdasarkan pengalaman, intuisi, dan penyesuaian waktu nyata (*real-time adjustment*). Strategi ini fleksibel, namun cenderung subyektif dan rentan terhadap bias personal. Chilton (2022) mengemukakan bahwa pada lingkungan proyek berskala besar, pendekatan ini tidak dapat menjamin konsistensi alokasi dan sering menghasilkan konflik penjadwalan internal.

- Model Matematis

Model matematis menjadi salah satu pendekatan klasik namun tetap relevan dalam optimasi alokasi sumber daya proyek. Pendekatan ini mencakup teknik seperti *Linear Programming* (LP), *Mixed Integer Programming* (MIP), dan *Goal Programming*, yang digunakan untuk memecahkan masalah dengan sejumlah *constraint* dan variabel keputusan yang dapat dihitung secara kuantitatif. Dalam studi terbaru, (L. Bai et al., 2024b) mengembangkan *hybrid simulation model* berbasis pemrograman matematis untuk alokasi sumber daya bersama dalam portofolio proyek. Model tersebut terbukti mampu menyelesaikan masalah keterbatasan sumber daya yang saling tumpang tindih, sekaligus mengefisienkan distribusi waktu dan tenaga kerja antar proyek.

Lebih lanjut, pendekatan matematis dapat dibedakan menjadi dua kategori utama:

- *Time-Oriented Model*, Menitikberatkan pada pencapaian tenggat waktu (*deadlines*) dengan fleksibilitas penggunaan sumber daya. Cocok digunakan dalam proyek dengan batas waktu yang ketat, di mana pengaturan urutan tugas menjadi prioritas utama.
- *Resource-Constrained Model*, Fokus pada pemanfaatan maksimum dari sumber daya terbatas (manusia, peralatan, atau anggaran), dengan asumsi bahwa jadwal proyek dapat disesuaikan untuk mengakomodasi kendala kapasitas.

Kedua pendekatan ini sering kali diintegrasikan dalam simulasi berbasis skenario untuk mengidentifikasi alokasi optimal berdasarkan prioritas proyek dan perubahan variabel eksternal.

- Model Simulasi dan Pembelajaran Mesin

L. Bai et al. (2024b) mengembangkan *Hybrid Simulation Model* untuk mengelola alokasi sumber daya bersama di antara proyek portofolio. Model ini menggabungkan simulasi stokastik dengan *feedback* berbasis prediksi dari *machine learning* untuk memperkirakan kemungkinan *bottleneck*, durasi penyelesaian, dan konflik alokasi.

Aratovskyi & Liubchenko (2024) menyimpulkan bahwa pendekatan pembelajaran mesin (misalnya ANN atau *Gradient Boosting*) memberikan akurasi prediksi yang tinggi terhadap beban kerja proyek dan durasi tugas, serta dapat digunakan untuk membangun sistem pendukung keputusan berbasis data historis dan aktual.

2.9 Manajemen Risiko Proyek

Manajemen risiko merupakan elemen penting dalam pengelolaan proyek, khususnya dalam konteks proyek teknologi informasi dan pengembangan perangkat lunak yang dikenal memiliki tingkat ketidakpastian tinggi. Tujuan utama dari manajemen risiko adalah mengidentifikasi, mengevaluasi, dan mengendalikan potensi risiko sebelum risiko tersebut berdampak secara signifikan terhadap keberhasilan proyek. Menurut Secundo et al. (2023), pendekatan tradisional dalam manajemen risiko semakin diperkaya dengan penerapan teknologi seperti *machine learning* dan *big data analytics*, yang memungkinkan organisasi mendeteksi pola risiko secara proaktif dan melakukan mitigasi secara prediktif.

Seiring dengan meningkatnya kompleksitas proyek, pendekatan manajemen risiko kini lebih menekankan pada integrasi data historis, pembelajaran mesin, serta sistem pendukung keputusan untuk meningkatkan akurasi dan kecepatan pengambilan keputusan. Dalam proyek-proyek *modern*, manajemen risiko tidak hanya bersifat reaktif tetapi juga proaktif dan adaptif, mencakup aspek teknis, organisasi, dan lingkungan secara menyeluruh (Li et al., 2024).

2.9.1 Jenis Risiko

Risiko dalam proyek dapat diklasifikasikan ke dalam beberapa kategori utama, yang masing-masing memiliki karakteristik dan pendekatan penanganan yang berbeda. Berikut adalah klasifikasi risiko yang umum dijumpai dalam proyek teknologi informasi:

Tabel 2-8 Kategori Risiko dalam Proyek TI

Kategori Risiko	Contoh Risiko	Dampak Umum
<i>Technical</i>	Bug kritis, kegagalan integrasi sistem, teknologi tidak kompatibel	Penurunan kualitas sistem, keterlambatan pengembangan
<i>Operational</i>	Gangguan proses kerja, miskomunikasi tim, kurang dokumentasi	Ketidakefisienan, duplikasi kerja, kesalahan implementasi
<i>Financial</i>	Pembengkakan biaya, anggaran tidak realistis, biaya vendor naik	Pengurangan <i>scope</i> proyek, konflik dengan sponsor
<i>Legal</i>	Pelanggaran lisensi, isu hak cipta, kebocoran data pribadi	Risiko litigasi, sanksi hukum, hilangnya kepercayaan
<i>Strategic</i>	Proyek tidak sesuai arah bisnis, kurang dukungan eksekutif	Ketidaksesuaian hasil proyek, pembatalan proyek
<i>Compliance</i>	Tidak patuh pada standar seperti ISO, GDPR, atau kebijakan internal	Audit negatif, reputasi organisasi menurun
<i>Market</i>	Perubahan tren pengguna, kompetitor merilis produk serupa	Gagal adopsi pasar, potensi ROI rendah
<i>Project Management</i>	Estimasi waktu salah, <i>scope creep</i> , manajemen risiko lemah	Keterlambatan, peningkatan beban kerja, <i>delivery</i> tidak sesuai
<i>Environmental</i>	Gangguan cuaca ekstrem, bencana alam, pandemi, gangguan listrik/server	Gangguan operasional serius, penundaan besar dalam proyek

Klasifikasi ini memudahkan proses prioritisasi risiko dan penyusunan strategi mitigasi yang sesuai (Khalilzadeh et al., 2024; Mumtaz et al., 2025; Nikolaenko & Sidorov, 2023)

2.9.2 Proses Manajemen Risiko

Proses manajemen risiko proyek secara umum terdiri dari empat tahap utama yang bersifat iteratif dan berkelanjutan:

Tabel 2-9 Proses Manajemen Risiko Proyek TI

Tahapan	Deskripsi	Contoh Aktivitas
Identifikasi Risiko	Menentukan potensi risiko yang dapat mengganggu tujuan proyek	<i>Brainstorming, checklist, analisis data proyek sebelumnya</i>
Analisis Risiko	Menilai tingkat kemungkinan dan dampak setiap risiko	Matriks risiko, FMEA (<i>Failure Mode and Effect Analysis</i>)
Perencanaan Respons	Menentukan strategi pengelolaan untuk setiap risiko	<i>Strategi avoid, mitigate, transfer, atau accept</i>
Monitoring & Kontrol	Mengevaluasi efektivitas tindakan yang diambil serta mendeteksi risiko baru secara berkala	<i>Update log risiko, evaluasi mingguan, penyesuaian strategi</i>

Pendekatan ini sejalan dengan model maturitas risiko seperti yang dijelaskan oleh Nikolaenko & Sidorov (2023), di mana peningkatan tingkat maturitas berbanding lurus dengan keberhasilan pengendalian risiko proyek TI.

Agar proses ini berjalan optimal, organisasi perlu membangun kultur risiko yang kuat, menyediakan pelatihan, serta melibatkan *stakeholder* sejak awal untuk meningkatkan akurasi identifikasi dan komitmen terhadap penanganan risiko.

2.9.3 Peran Model Prediktif

Pemanfaatan kecerdasan buatan dan model prediktif semakin banyak digunakan untuk mendukung proses manajemen risiko, khususnya dalam proyek berskala besar. Li et al. (2024) menunjukkan bahwa *machine learning* dapat mengidentifikasi risiko tersembunyi berdasarkan data proyek sebelumnya, memperkirakan probabilitas kegagalan tugas, dan menyarankan tindakan preventif secara otomatis. Model prediktif seperti *decision tree*, *gradient boosting*, dan *neural networks* telah digunakan dalam sistem pendukung keputusan untuk memprediksi risiko keterlambatan proyek, *overbudget*, atau konflik sumber daya.

Menurut Mumtaz et al. (2025), integrasi antara *big data* dan *machine learning* dalam manajemen risiko dapat mengubah pendekatan tradisional menjadi berbasis data dan berkelanjutan, yang tidak hanya menanggulangi risiko yang diketahui, tetapi juga memunculkan potensi risiko yang sebelumnya tidak terlihat. Pendekatan ini mendorong transformasi organisasi menuju sistem manajemen risiko yang

adaptif, otomatis, dan lebih responsif terhadap dinamika eksternal. Berikut manfaat Model Prediktif dalam Manajemen Risiko Proyek:

- **Deteksi Risiko Dini**
Mendeteksi proyek atau komponen yang berpotensi gagal sebelum risiko terjadi secara nyata.
- **Rekomendasi Mitigasi Otomatis**
Memberikan saran tindakan berdasarkan pola risiko yang telah terjadi di proyek sebelumnya.
- **Prediksi Akurat Beban & Kinerja**
Mengidentifikasi tim yang mengalami overloading atau keterlambatan berdasarkan progres tugas.
- **Visualisasi Risiko Proyek**
Menyediakan dashboard visual seperti heatmap dan grafik tren yang mendukung pemantauan aktif.
- **Adaptif terhadap Perubahan**
Model dapat dilatih ulang agar menyesuaikan dengan kondisi dan struktur proyek yang berbeda.

Untuk implementasinya, digunakan teknik seperti *classification* (untuk memisahkan proyek berisiko dan tidak), *regression* (untuk memprediksi waktu keterlambatan), atau *time series analysis* (untuk memetakan tren kinerja proyek). Berikut adalah contoh komponen input dan output dari sistem prediktif risiko:

Tabel 2-10 Input dan Output Model Prediktif Risiko Proyek

Komponen	Contoh
Input Data	Durasi <i>task</i> , frekuensi <i>scope change</i> , beban kerja tim, tingkat absensi
Model Digunakan	<i>Random Forest</i> , <i>Gradient Boosting</i> , ANN
Output	Skor risiko proyek (0–1), klasifikasi risiko (tinggi, sedang, rendah)
Tindakan	Eskalasi ke manajer, penjadwalan ulang, alokasi ulang sumber daya

Namun, seperti dikemukakan oleh Secundo et al. (2023), tantangan utama dalam penerapan model prediktif dalam manajemen risiko proyek adalah kualitas data historis, kompleksitas interpretasi hasil, dan keterbukaan manajer proyek terhadap rekomendasi otomatis. Banyak organisasi masih mengalami kesenjangan

antara kemampuan sistem dalam mendeteksi risiko dan kesiapan organisasi untuk meresponsnya secara proaktif. Bahkan dalam beberapa kasus, terdapat kecenderungan untuk mengabaikan risiko yang tidak menyenangkan, atau yang dinilai bertentangan dengan tujuan strategis jangka pendek, sebuah fenomena yang dikenal sebagai *organizational resistance to automated risk-based decision support*. Oleh karena itu, keberhasilan penggunaan model prediktif sangat tergantung pada integrasi teknologi dengan budaya risiko yang sehat serta sistem manajemen proyek yang responsif dan kolaboratif.

2.10 Rancangan UML

Unified Modeling Language (UML) adalah bahasa visual standar yang digunakan untuk memodelkan struktur dan perilaku sistem perangkat lunak. UML memfasilitasi proses dokumentasi, komunikasi, dan validasi sistem, terutama pada tahap awal perancangan. Dengan berbagai jenis diagramnya, UML memungkinkan pengembang, analis, dan pemangku kepentingan untuk memahami sistem secara menyeluruh dari berbagai sudut pandang (Fu'adi et al., 2022; Mahardika et al., 2024).

Dalam konteks sistem pendukung keputusan berbasis *hybrid machine learning*, UML memiliki peran penting dalam menggambarkan relasi antara modul pengambilan keputusan, *engine machine learning*, serta interaksi pengguna terhadap sistem. Margaretha & Voutama (2023) menyatakan bahwa penggunaan UML dapat memperjelas alur logika sistem berbasis web, mulai dari proses input data, pemrosesan prediktif, hingga penyajian hasil ke pengguna dalam bentuk rekomendasi atau visualisasi risiko.

2.10.1 Use Case Diagram

Use Case Diagram digunakan untuk mendeskripsikan kebutuhan sistem dari perspektif pengguna. Diagram ini menggambarkan aktor dan *use case* (fitur atau fungsi sistem), serta hubungan antara keduanya seperti *include* dan *extend*. Menurut Mahardika et al. (2024), diagram ini berperan penting dalam tahap awal pengembangan sistem untuk mengidentifikasi fungsionalitas utama.

Tabel 2-11 Komponen Utama Use Case Diagram

Elemen	Deskripsi
Aktor	Entitas eksternal yang berinteraksi dengan sistem
<i>Use Case</i>	Fungsi atau layanan yang disediakan oleh sistem
<i>Association Line</i>	Hubungan antara aktor dan <i>use case</i>
<i>System Boundary</i>	Batasan ruang lingkup sistem

2.10.2 Activity Diagram

Activity Diagram adalah representasi visual dari alur proses dalam sistem, menampilkan aktivitas, kondisi logis, dan urutan eksekusi. Diagram ini mirip

flowchart dan berguna untuk menganalisis proses bisnis dan logika sistem (Fu'adi et al., 2022).

Tabel 2-12 Komponen Utama Activity Diagram

Elemen	Deskripsi
<i>Activity</i>	Tugas atau proses yang dilakukan dalam sistem
<i>Decision Node</i>	Titik percabangan logika berdasarkan kondisi tertentu
<i>Merge/Fork Node</i>	Penggabungan atau pemisahan jalur eksekusi
<i>Start/End Node</i>	Titik awal dan akhir aktivitas

2.10.3 Class Diagram

Class Diagram memodelkan struktur statis sistem, menampilkan kelas, atribut, metode, dan relasi antar kelas. Diagram ini sangat penting dalam perancangan basis data dan pengembangan OOP (Margaretha & Voutama, 2023).

Tabel 2-13 Elemen Struktur Class Diagram

Elemen	Deskripsi
<i>Class</i>	Struktur objek yang terdiri dari atribut dan operasi
<i>Attribute</i>	Properti atau data dari sebuah kelas
<i>Operation</i>	Fungsi yang dapat dilakukan oleh kelas
<i>Association</i>	Relasi antar kelas
<i>Inheritance</i>	Pewarisan atribut dan metode dari kelas induk

2.10.4 Component Diagram

Component Diagram menjelaskan struktur logis dari sistem dan ketergantungan antar modul perangkat lunak. Digunakan untuk memetakan fungsi sistem ke dalam komponen independen (Voutama et al., 2022).

Tabel 2-14 Komponen dalam Component Diagram

Elemen	Deskripsi
<i>Component</i>	Modul independen yang memiliki fungsionalitas spesifik
<i>Interface</i>	Titik interaksi antara komponen
<i>Dependency</i>	Hubungan yang menunjukkan ketergantungan antar komponen

2.10.5 Deployment Diagram

Deployment Diagram menggambarkan konfigurasi fisik sistem, node perangkat keras, dan distribusi komponen ke dalam node tersebut. Diagram ini penting dalam perencanaan infrastruktur sistem (Yoga & Ardhana, 2021).

Tabel 2-15 Elemen Kunci Deployment Diagram

Elemen	Deskripsi
<i>Node</i>	Perangkat keras atau lingkungan tempat komponen dijalankan

<i>Artifact</i>	Komponen perangkat lunak yang di- <i>deploy</i> pada node
<i>Communication</i>	Hubungan atau koneksi antar <i>node</i>

2.11 Aplikasi

Pengembangan sistem pendukung keputusan (SPK) berbasis web telah menjadi pendekatan populer dalam membangun solusi digital yang mampu menangani proses pengambilan keputusan yang kompleks secara lebih efisien dan terjangkau. Aplikasi SPK umumnya dirancang untuk dapat diakses melalui peramban (*browser*), memungkinkan fleksibilitas akses lintas perangkat dan integrasi real-time dengan basis data serta model komputasi keputusan (Aminuddin et al., 2022).

Sistem seperti ini biasanya dibangun menggunakan arsitektur tiga lapis (*three-tier architecture*) yang terdiri dari:

- *Presentation Layer* (antarmuka pengguna),
- *Application Layer* (logika bisnis dan pemrosesan keputusan), dan
- *Data Layer* (basis data dan model SPK).

Hendri et al. (2023) menekankan bahwa salah satu keunggulan aplikasi SPK berbasis web adalah kemampuannya dalam melakukan validasi dan seleksi data secara sistematis serta menampilkan hasil keputusan secara langsung dalam bentuk tabel, grafik, atau rekomendasi akhir yang mudah dipahami.

Dalam praktiknya, aplikasi SPK juga mendukung berbagai metode pengambilan keputusan, seperti *Analytical Hierarchy Process* (AHP), *Profile Matching*, *Weighted Product*, dan lain sebagainya. Penerapan metode-metode ini dilakukan melalui pemrograman logika komputasi dalam *backend* sistem, sehingga pengguna hanya perlu menginput data atau kriteria yang relevan untuk mendapatkan hasil akhir secara otomatis (Kaunan et al., 2023; Niis Molo et al., 2022).

Di sisi lain, Wayan Arya Wiguna et al. (2022) menjelaskan bahwa perancangan aplikasi SPK yang ideal juga memperhatikan aspek *usability* dan keamanan. Desain antarmuka yang intuitif dan sistem otentikasi pengguna menjadi kunci untuk memastikan pengalaman penggunaan yang nyaman dan aman.

Tabel 2-16 Komponen Umum dalam Aplikasi SPK Berbasis Web

Komponen	Deskripsi
Antarmuka Pengguna	Halaman input, form kriteria, dan hasil rekomendasi
Basis Data	Menyimpan informasi alternatif, bobot, nilai evaluasi, dan hasil perhitungan
Modul Perhitungan	Implementasi metode SPK (misal: <i>AHP</i> , <i>Profile Matching</i> , dsb.)

Sistem Otentikasi	Pengelolaan hak akses pengguna dan keamanan data
Visualisasi Output	Grafik, tabel, atau teks rekomendasi hasil keputusan

Dengan menggunakan teknologi web, pengembangan aplikasi SPK menjadi lebih terjangkau dan mudah dalam pemeliharaan. Pendekatan ini sangat cocok digunakan dalam organisasi atau instansi yang memerlukan proses seleksi, evaluasi, atau rekomendasi secara berkala dan berbasis data.